



Национальный Исследовательский
Университет «Высшая Школа Экономики»

2026

Введение в машинное обучение

Лекция 1



Содержание

- 1 Прикладная задача и её постановка
- 2 Представление данных и признаки
- 3 Типы задач машинного обучения
- 4 Модель, предсказание и функция потерь
- 5 Обучение и оценка качества



Прикладная задача и её постановка

01

Объект, целевой ответ и назначение прогноза.
Математические пространства объектов и ответов.



Задача сервиса доставки

При подтверждении заказа сервис оценивает время до вручения.
Этот прогноз используют при планировании занятости курьеров.

Элемент постановки	Определение
Объект	Заказ и состояние сервиса в момент подтверждения
Целевой ответ	Фактическое время от подтверждения до вручения
Данные	История завершённых доставок с признаками на момент прогноза
Применение	Новые заказы при меняющихся маршрутах и нагрузке

Назначение прогноза определяет, какие ошибки существенны и как измерять качество.



Объекты и целевая переменная

Машинное обучение изучает методы восстановления закономерностей по конечной выборке наблюдений.

$$x \in \mathbb{X}$$

$\mathbb{X}$ — пространство объектов.

$$y \in \mathbb{Y}$$

$\mathbb{Y}$ — пространство значений целевой переменной.

Пример: x — заказ в момент подтверждения,
 y — время от подтверждения до вручения, в минутах.



Представление данных и признаки

02

Функции признаков и числовое кодирование.
Выборка и матрица признаков.
Доступность информации при прогнозе.



Признаки объекта (Features)

Признак описывает свойство объекта, доступное в момент прогноза.

$$f_j: \mathbb{X} \rightarrow D_j$$

$f_j(x)$ — значение признака для объекта x .

D_j — множество возможных значений.

Признак заказа	Пример значения
Расчётная длина маршрута	3,2 км
Район доставки	Северный
Число позиций в заказе	7

Для числовой модели признаки кодируют в вектор. Способ кодирования зависит от их типа.



Типы признаков

Тип	Область значений	Структура
Бинарный	$\{0, 1\}$	Два возможных значения
Числовой	$\mathbb{R}$ или его подмножество	Осмысленные арифметические операции
Категориальный	$C = \{c_1, \dots, c_k\}$	Множество без заданного порядка
Порядковый	C с отношением порядка	Порядок не задаёт расстояний
Set-valued	Подмножества C	Несколько категорий одновременно
Структурный	Тексты, изображения, звук	Требуется выбор представления

Код категории не определяет ни расстояние между категориями, ни их порядок.



Кодирование категориального признака

Район доставки принимает значения «Северный», «Центральный», «Южный».

Район	Код	Индикаторы: one-hot
Северный	1	(1, 0, 0)
Центральный	2	(0, 1, 0)
Южный	3	(0, 0, 1)

При использовании кода как числа модель может учитывать порядок и разности кодов. Индикаторы задают отдельный признак для каждой категории.

Обучающая выборка и обозначения

$$x_i = (x_{i1}, \dots, x_{id}) \in \mathbb{R}^d$$

d признаков на объект.

$$X = \{(x_i, y_i)\}_{i=1}^{\ell}$$

ℓ размеченных наблюдений.

$$F = (x_{ij}) \in \mathbb{R}^{\ell \times d}$$

$$y = (y_1, \dots, y_{\ell})^T$$

После кодирования: F — числовая матрица признаков, y — вектор ответов.



Доступность признаков во времени

Историческая запись содержит больше информации, чем доступно при прогнозе.

Признак	В момент подтверждения	Решение
Расчётное расстояние маршрута	Известно	Используем
Состав и размер заказа	Известны	Используем
Текущая загрузка курьеров	Известна по журналу событий	Используем срез на этот момент
Фактическая длительность сборки	Появится позже	Утечка
Фактическое время вручения	Появится позже	Из него строим таргет

Корректность признака определяется моментом доступности, а не корреляцией с таргетом.



Типы задач машинного обучения

03

Способ обучения и структура ответа.

Регрессия, классификация, ранжирование, прогнозирование.

Структурированные ответы и задачи без разметки.



Задача и способ обучения

Способ обучения	Обучающий сигнал	Пример
С учителем Supervised	Ответы y для объектов x	Длительность доставки по заказу
Без учителя Unsupervised	Структура наблюдаемых x	Группы клиентов по поведению
С частичной разметкой Semi-supervised	Размеченные и неразмеченные объекты	Классификация с небольшой разметкой
Самоконтролируемое Self-supervised	Задача, построенная из самих данных	Предсказание скрытого фрагмента текста
С подкреплением Reinforcement learning	Вознаграждения за последовательность действий	Управление агентом в среде

Способ обучения задаёт источник обучающего сигнала, тип задачи — структуру требуемого ответа.



Регрессия (Regression)

Скалярная регрессия

$$Y \subseteq \mathbb{R}$$

Время доставки заказа.
Объём продаж за период.
Стоимость объекта.

Многомерная регрессия

$$Y \subseteq \mathbb{R}^m$$

Длительности сборки и пути.
Координаты положения объекта.
Продажи по нескольким категориям.

Структура ответа задаёт, какие отклонения и отношения между координатами имеют смысл.



Классификация (Classification)

Ответ задаёт принадлежность объекта к одному или нескольким классам.

Постановка	Пространство ответов	Пример
Бинарная	$y \in \{0, 1\}$	Нарушен ли срок доставки
Многоклассовая	$y \in \{1, \dots, K\}$	Одна основная причина обращения
Многометочная	$y \in \{0, 1\}^K$	Все темы обращения одновременно

В многометочной задаче каждая координата ответа указывает, относится ли объект к соответствующему классу.



Прогнозирование рядов (Forecasting)

Сервис планирует число курьеров на следующую неделю.
Для этого нужен прогноз количества заказов на каждый день.

Элемент задачи	В этом примере
История	Количество заказов по дням за предыдущие недели
Дополнительные признаки	День недели, праздники, запланированные акции
Горизонт прогноза	Следующие 7 дней
Ответ	Семь чисел: прогноз спроса на каждый день

Время задаёт порядок наблюдений. При проверке воспроизводим прогноз из прошлого в будущее.



Ранжирование (Ranking) и рекомендации

В ранжировании нужно упорядочить кандидатов по полезности для конкретного запроса или пользователя.

Приложение	Контекст	Что упорядочиваем
Поиск	Текст запроса	Документы по соответствию запросу
Рекомендации	Пользователь и его интересы	Товары или фильмы по интересу для него

Один из подходов: модель присваивает каждому кандидату числовую оценку, после чего кандидатов сортируют по убыванию этой оценки.



Структурированные ответы (Structured prediction)

Задача	Объект	Ответ
Сегментация	Изображение	Класс каждого пикселя
Распознавание речи	Аудиосигнал	Последовательность слов
Машинный перевод	Текст на одном языке	Текст на другом языке
Генерация	Условие, например текстовое описание	Текст, изображение или другой объект

Компоненты ответа связаны: в тексте важен порядок слов,
в сегментации — согласованность классов соседних пикселей.
Длина ответа может различаться у разных объектов.



Задачи без готовой разметки

$$X = \{x_i\}_{i=1}^{\ell}$$

Задача	Результат	Пример
Кластеризация	Группы по выбранному сходству	Сегменты клиентов по поведению
Снижение размерности	Компактное представление	Сжатие и визуализация описаний
Оценивание распределения	Модель распределения данных	Генерация новых наблюдений
Поиск аномалий	Степень нетипичности объекта	Необычные операции или сигналы

Наличие разметки и критерий качества зависят от постановки. Поиск аномалий бывает и с учителем.



Модель, предсказание и функция потерь

04

Семейство моделей и алгоритм обучения.
Ограничения на допустимые зависимости.
Потеря на одном объекте.



Модель и семейство моделей

$$a: X \rightarrow Y, a \in \mathcal{A}$$

Модель a сопоставляет объекту x прогноз $a(x)$.

Семейство $\mathcal{A}$ — множество моделей, среди которых выбираем решение.

Семейство задаёт допустимую форму зависимости.

Алгоритм обучения по выборке выбирает конкретную модель из $\mathcal{A}$.

Линейное семейство: пример модели

Пусть объект представлен вектором из d числовых признаков.

$$a_w(x) = w_0 + w_1x_1 + \dots + w_dx_d$$

Коэффициенты при признаках — веса модели, w_0 — свободный член.

Семейство $\mathcal{A}$ содержит такие модели при всех вещественных значениях весов.
Обучение выбирает веса по наблюдаемым данным.

Здесь линейная модель иллюстрирует семейство. Её обучение разберём в следующих лекциях.

Функция потерь на одном объекте

Потеря $L(y, z)$ задаёт цену прогноза z при истинном ответе y .

$$L: \mathbb{Y} \times \mathbb{Y} \rightarrow \mathbb{R}_{\geq 0}, z = a(x)$$

Регрессия: $y, z \in \mathbb{R}$

$$L_2(y, z) = (y - z)^2$$

Классификация: $y, z \in \{1, \dots, K\}$

$$L_{0/1}(y, z) = 1\{y \neq z\}$$

Индикатор $1\{y \neq z\}$ равен 1 при ошибке классификации и 0 при правильном ответе.



Обучение и оценка качества

05

- 5.1. Эмпирический риск и оптимизация
- 5.2. Метрики и выбор функции потерь
- 5.3. Обобщение и протокол оценки



Потеря, критерий обучения и метрика

Понятие	Что измеряет	Как используется
Потеря (Loss)	Цену одной ошибки	Сравниваем прогноз с известным ответом
Критерий обучения	Ошибки модели на обучающей выборке	Минимизируем при выборе модели
Метрика (Metric)	Нужное нам свойство качества	Оцениваем результат на новых данных

Например, средний квадрат ошибки можно и минимизировать при обучении, и вычислять при проверке. Роль зависит от того, зачем и на каких данных мы его считаем.

Эмпирический риск и задача обучения

Эмпирический риск — средняя потеря на обучающей выборке:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, a(x_i))$$

Ищем модель из семейства $\mathcal{A}$ с наименьшим значением этого критерия:

$$a^* \in \operatorname{argmin}_{a \in \mathcal{A}} Q(a, X)$$

argmin возвращает решение задачи минимизации. Способ поиска зависит от модели и потерь.

Абсолютные ошибки: MAE, MSE, RMSE

$$r_i = a(x_i) - y_i$$

$$\text{MAE} = \frac{1}{\ell} \sum_{i=1}^{\ell} |r_i|$$

Средний модуль отклонения.
Размерность ответа.

$$\text{MSE} = \frac{1}{\ell} \sum_{i=1}^{\ell} r_i^2$$

Квадратичный штраф за остаток.
Квадрат размерности ответа.

$$\text{RMSE} = \sqrt{\text{MSE}}$$

Размерность ответа. Порядок моделей
совпадает с MSE на этой выборке.



Метрика меняет выбор модели

Заказ	Факт, мин	Прогноз А	Прогноз В
1	20	20	24
2	30	30	34
3	40	40	44
4	50	50	54
5	60	75	64

Метрика	А	В
MAE, мин	3	4
MSE, мин ²	45	16
RMSE, мин	6,71	4

MAE предпочитает А.

RMSE предпочитает В.

А ошибается редко, но сильно. Выбор между А и В требует определить цену такого промаха.

R^2 : ошибка относительно вариации ответа

$$R^2 = 1 - \frac{\sum_{i=1}^{\ell} (y_i - a(x_i))^2}{\sum_{i=1}^{\ell} (y_i - \bar{y})^2}, \bar{y} = \frac{1}{\ell} \sum_{i=1}^{\ell} y_i$$

Значение	Интерпретация на оцениваемой выборке
$R^2 = 1$	Прогнозы совпадают с ответами
$R^2 = 0$	Ошибка совпадает с прогнозом среднего $\bar{y}$ этой выборки
$R^2 < 0$	Ошибка больше, чем у прогноза среднего $\bar{y}$ этой выборки

При постоянном y формула не определена. R^2 может быть отрицательным без нижней границы.

Относительная ошибка и масштаб объектов

$$\text{MAPE} = \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{|y_i - a(x_i)|}{|y_i|}$$

Каждый объект имеет равный вес
в среднем относительных ошибок.
Не определена при $y_i = 0$.
Малые $|y_i|$ дают большие вклады.

$$\text{WAPE} = \frac{\sum_{i=1}^{\ell} |y_i - a(x_i)|}{\sum_{i=1}^{\ell} |y_i|}$$

Нормирует общую абсолютную
ошибку на суммарный объём.
Не определена при $\sum |y_i| = 0$.
При равной относительной ошибке
вклад крупных объектов больше.

Пример: факты (1, 100), ошибки (1, 10). MAPE = 55%, WAPE $\approx$ 10,9%.

Ошибка в логарифмическом масштабе

$$\text{MSLE} = \frac{1}{\ell} \sum_{i=1}^{\ell} (\log(1 + y_i) - \log(1 + a(x_i)))^2$$

$$\text{RMSLE} = \sqrt{\text{MSLE}}$$

Для неотрицательных величин с большим разбросом масштаба, например продаж по товарам. Логарифм уменьшает влияние крупных абсолютных отклонений при больших значениях ответа.

RMSLE измеряет отклонения $\log(1 + y)$. Она не равна средней процентной ошибке.



Как потеря влияет на прогноз

Даже при одинаковых признаках время доставки может различаться. Функция потерь определяет, какую характеристику этого разброса стремится предсказать модель.

Потеря	К какому прогнозу стремимся
Квадратичная	Среднее время при данных признаках
Абсолютная	Медианное время при данных признаках

Это ориентир при свободном выборе прогноза. Возможности конкретной модели ограничены её семейством.

Потеря Хьюбера (Huber loss)

$$L_{\delta}(r) = \begin{cases} \frac{r^2}{2}, & |r| \leq \delta \\ \delta(|r| - \frac{\delta}{2}), & |r| > \delta \end{cases}$$



$\delta > 0$ — порог перехода.

При малых ошибках штраф квадратичный, при больших растёт линейно.

На графике $\delta = 1,5$. По сравнению с квадратичной потерей крупные промахи получают меньший штраф.

Квантильная потеря (Quantile loss)

$$L_{\tau}(y, z) = \begin{cases} \tau(y - z), & y \geq z \\ (1 - \tau)(z - y), & y < z \end{cases}$$



$0 < \tau < 1$ задаёт веса ошибок.

На графике $\tau = 0,8$.

Недооценка времени в 4 раза
дороже такой же переоценки.

При $\tau = 0,8$ ориентир — время, в которое укладываются 80% заказов с такими признаками.

Accuracy: доля правильных ответов

$$\text{Accuracy} = \frac{1}{\ell} \sum_{i=1}^{\ell} 1\{a(x_i) = y_i\}$$

Фактический исход	Прогноз «вовремя»	Прогноз «опоздание»
Вовремя: 950 заказов	930	20
Опоздание: 50 заказов	20	30

Верно 960 ответов из 1000: accuracy = 96%.

При этом модель пропустила 20 из 50 опозданий.



Критерий качества в задаче доставки

Что важно сервису	Чем измеряем качество
Типичный размер отклонения в минутах	MAE
Крупные отклонения особенно нежелательны	RMSE
Недооценка и переоценка имеют разную цену	Средняя стоимость ошибок с учётом их знака

Критерий обучения выбираем под эту цель. Дополнительно проверяем ошибки по районам, нагрузке и времени суток: среднее по сервису может скрыть проблемы в отдельных группах заказов.




Обучающая, валидационная и тестовая выборки

Качество на данных обучения может быть завышено: модель подбирали по их ответам. Для выбора и проверки нужны отдельные данные.

Часть данных	Назначение
Train: обучение	Подбираем параметры модели
Validation: выбор	Сравниваем варианты модели и выбираем лучший
Test: проверка	Оцениваем выбранное решение после завершения подбора

Все части должны соответствовать сценарию применения. Далее посмотрим, зачем их разделять.

Ошибка на обучении и на новых объектах



MSE, мин ²	Train	Valid.
Линейная	0,38	0,13
Гибкая	0	6,58

Увеличение гибкости позволяет точнее описать train, но не гарантирует качество на validation.

Синтетический пример. Сравнение семейств требует данных, не использованных для подгонки.

Подбор модели и итоговая проверка

1 Обучаем варианты на **train**

Например, сравниваем разные наборы признаков и семейства моделей.

2 Сравниваем варианты на **validation**

Считаем заранее выбранную метрику и фиксируем решение.

3 Оцениваем решение на **test**

Получаем итоговую оценку качества на отложенных данных.

Если выбирать модель по **test**, он тоже становится частью подбора и теряет роль финальной проверки.



Разбиение для прогноза будущих заказов

Период	Роль	Что делаем
Январь — март	Train	Оценить преобразования и параметры
Апрель	Validation	Сравнить признаки, семейства, критерии
Май	Test	Один раз оценить выбранное решение
Июнь	Применение	Строить прогнозы для новых заказов

Случайное смешивание дат может скрыть изменения нагрузки, сезонности и условий доставки.

Ответы на test не используем при подборе модели и признаков.

Математическая постановка: резюме

$$X = \{(x_i, y_i)\}_{i=1}^{\ell}, x_i \in \mathbb{X}, y_i \in \mathbb{Y}$$

$$a \in \mathcal{A}, a: \mathbb{X} \rightarrow \mathbb{Y}$$

$$L: \mathbb{Y} \times \mathbb{Y} \rightarrow \mathbb{R}_{\geq 0}$$

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i, a(x_i))$$

$$a^* \in \operatorname{argmin}_{a \in \mathcal{A}} Q(a, X)$$



Вопросы