



Национальный Исследовательский
Университет «Высшая Школа Экономики»

2026

Линейная регрессия

Лекция 2



Формула оценки:

$$0.25 * ДЗ + 0.3 * ПР + 0.15 * КР + 0.3 * ЭКЗ$$

ДЗ – средний балл за все дз

ПР – средний балл за все проверочные (будет 3-4 штуки)

КР – балл за контрольную работу (в конец ноября – начало декабря по пройденным темам)

ЭКЗ – балл за экзамен



Содержание

- 1 МНК для одного признака
- 2 Матричное решение МНК
- 3 Зависимые признаки и устойчивость
- 4 Обработка признаков
- 5 Интерпретация и проверка модели
- 6 Линейная регрессия в Python



МНК для одного признака

01

Линейная модель: наклон и свободный член
Невязка и сумма квадратов ошибок
Условия минимума и расчёт коэффициентов



Обучение линейной модели

В первой лекции задали семейство моделей и критерий обучения.
Теперь найдём веса, минимизирующие квадратичную ошибку.

$$a_w(x) = w_0 + \sum_{j=1}^d w_j x_j$$

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a_w(x_i) - y_i)^2 \rightarrow \min_w$$

МНК (ordinary least squares) выбирает веса с минимальным Q . Такие веса обозначим w^* .



Данные задачи доставки


Прогнозируем длительность доставки в момент подтверждения заказа.
Для первого расчёта используем один признак — расстояние маршрута.

Расстояние x , км	1	2	3	4	5
Время y , мин	18	20	25	29	33

$$a_w(x) = w_0 + w_1 x$$

Синтетическая обучающая выборка из первой лекции. Требуется определить w_0 и w_1 .

Невязки и квадратичный критерий



$$r_i = a_w(x_i) - y_i$$

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} r_i^2$$

На графике пробная
прямая: $12 + 4x$.

Изменяя веса, меняем
все невязки.

Оранжевые отрезки — отклонения прогноза от наблюдаемого времени.



Условие минимума по свободному члену

$$Q(w_0, w_1) = \frac{1}{\ell} \sum_{i=1}^{\ell} (w_0 + w_1 x_i - y_i)^2$$

В точке минимума w^* производная по w_0 равна нулю:

$$\frac{2}{\ell} \sum_{i=1}^{\ell} (w_0^* + w_1^* x_i - y_i) = 0$$

$$w_0^* = \bar{y} - w_1^* \bar{x}$$

$\bar{x}$ и $\bar{y}$ — выборочные средние. МНК-прямая проходит через точку $(\bar{x}, \bar{y})$.

Условие минимума по наклону

В точке минимума w^* производная по w_1 равна нулю:

$$\frac{2}{\ell} \sum_{i=1}^{\ell} x_i (w_0^* + w_1^* x_i - y_i) = 0$$

Подставим $w_0^* = \bar{y} - w_1^* \bar{x}$ и сгруппируем центрированные значения:

$$w_1^* = \frac{\sum_{i=1}^{\ell} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{\ell} (x_i - \bar{x})^2}$$

Знаменатель положителен, если среди x_i есть хотя бы два разных значения.



Расчёт коэффициентов по выборке

$x_i - 3$	-2	-1	0	1	2
$y_i - 25$	-7	-5	0	4	8
Произведение	14	5	0	4	16

$$w_1^* = \frac{39}{10} = 3.9, w_0^* = 25 - 3.9 \cdot 3 = 13.3$$

Прогноз: $a(x) = 13,3 + 3,9x$. Для маршрута 3,5 км получаем 26,95 мин.



Невязки найденного решения

х, км	Факт у	Прогноз а(х)	r = а(х) – у
1	18	17,2	-0,8
2	20	21,1	1,1
3	25	25,0	0,0
4	29	28,9	-0,1
5	33	32,8	-0,2

$$a(x) = 13.3 + 3.9x$$

$$MSE = \frac{1.9}{5} = 0.38$$

Расстояние — лишь один фактор. Добавим нагрузку сервиса и обобщим расчёт весов.



Матричное решение МНК

02

Матрица признаков и вектор прогнозов
Квадратичный критерий в матричной записи
Нормальные уравнения и условия решения



Несколько признаков одного заказа

Добавим нагрузку n — число активных заказов в момент прогноза.
Для всех наблюдений используем одни и те же три веса.

Заказ	Расстояние s , км	Нагрузка n	Время y , мин
1	1	2	18
2	2	1	20
3	3	3	25
4	4	2	29
5	5	4	33

$$\hat{y}_i = w_0 + w_1 s_i + w_2 n_i$$

Матричная запись линейной модели

F — матрица признаков размера $\ell \times d$. Добавим столбец единиц и обозначим расширенную матрицу через $A = [1 \ F]$.

$$A = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1d} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{\ell 1} & \cdots & x_{\ell d} \end{pmatrix}$$

$$w = (w_0, \dots, w_d)^T$$

$$\hat{y} = Aw, r = Aw - y$$

Размер A : $\ell \times (d + 1)$. В w — $d + 1$ весов; в $y, \hat{y}, r$ — ℓ значений. X — выборка.

Сумма квадратов ошибок в матричной записи

Для каждого заказа: r_i = прогноз – фактическое время.
Квадрат r_i^2 делает вклад ошибки неотрицательным.

Пример двух ошибок	Квадраты ошибок	Сумма
$r_1 = 2, r_2 = -3$	$2^2 = 4, (-3)^2 = 9$	$4 + 9 = 13$

$$r^T r = r_1^2 + \dots + r_\ell^2, r = Aw - y$$

$$Q(w) = \frac{1}{\ell} r^T r = \frac{1}{\ell} (Aw - y)^T (Aw - y)$$

^T означает транспонирование: вектор-столбец превращаем в строку и умножаем на столбец.

Условие минимума: нормальные уравнения

Для произвольных весов w ошибка равна $r = Aw - y$.

Производная по весу w_j учитывает столбец j матрицы A :

$$\frac{\partial Q(w)}{\partial w_j} = \frac{2}{\ell} \sum_{i=1}^{\ell} A_{ij} r_i$$

Пусть w^* — веса в точке минимума. Там все производные равны нулю:

$$A^T (Aw^* - y) = 0$$

$$A^T Aw^* = A^T y$$

A_{ij} — элемент строки i и столбца j . Последнее равенство — система уравнений для оптимальных весов.

Решение МНК и условие единственности

w — произвольные веса; w^* — любой набор весов, минимизирующий Q .

Для МНК критерий выпуклый: все решения нормальных уравнений являются минимумами, и каждый минимум удовлетворяет этим уравнениям.

$$A^T A w^* = A^T y$$

Если столбцы A линейно независимы, $A^T A$ обратима.

Умножаем обе части слева на $(A^T A)^{-1}$ и получаем единственное решение:

$$w^* = (A^T A)^{-1} A^T y$$

При зависимых столбцах минимум тоже существует, но веса неединственны. Эта формула неприменима.

Геометрический смысл МНК

Для всей выборки y — вектор фактических ответов, Aw — вектор прогнозов.
Изменяя веса, получаем разные допустимые векторы прогнозов.

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} ((Aw)_i - y_i)^2$$

Сумма квадратов ошибок — квадрат расстояния между этими векторами.
Поэтому МНК выбирает ближайший к y допустимый вектор Aw^* .

Это ортогональная проекция: невязка перпендикулярна пространству допустимых прогнозов.



Зависимые признаки и устойчивость

03

Линейная зависимость и ранг матрицы

Неединственность коэффициентов

Чувствительность решения и способы вычисления



Километры и метры: два признака об одном

Пусть s — расстояние в километрах, $u = 1000s$ — то же расстояние в метрах.
Добавили оба столбца. Как разделить между ними вклад расстояния?

Набор весов	Вклад расстояния	Для маршрута 3 км
$w_s = 3,9; w_u = 0$	$3,9s$	$3,9 \cdot 3 = 11,7$ мин
$w_s = 2,9; w_u = 0,001$	$2,9s + 0,001u$	$2,9 \cdot 3 + 0,001 \cdot 3000 = 11,7$ мин

В обоих случаях добавляем тот же свободный член 13,3 минуты.

Прогнозы совпадают при любом расстоянии, хотя веса различаются.



Почему нельзя обратить матрицу $A^T A$

В примере с километрами и метрами третий столбец A равен второму, умноженному на 1000. Он не добавляет новой информации.

$$A_2 = 1000A_1$$

Ранг — максимальное число независимых столбцов. Здесь столбцов три: единицы, километры, метры, а независимых только два.

По данным нельзя однозначно определить все три веса.

Матрица $A^T A$ необратима, поэтому формула с $(A^T A)^{-1}$ не работает.

Близкие признаки могут дать неустойчивые веса

Теперь x_1 и x_2 — два почти одинаковых измерения. При обучении могут появиться большие веса с разными знаками. Рассмотрим пример:

$$a(x) = 1001x_1 - 1000x_2$$

Первое измерение x_1	Второе измерение x_2	Прогноз
1	1	1
1	1,001	0
1	0,999	2

Изменение измерения всего на 0,001 меняет прогноз на 1. Веса усилили маленькое расхождение.



Почему формулу не вычисляют буквально

Формула описывает решение, но явное вычисление обратной матрицы может усилить ошибки округления и требует дополнительных вычислений.

Шаг, $p = d + 1$ — число весов	Вычислительные затраты
Сформировать $A^T A$	Порядка $\ell \cdot p^2$ операций
Вычислить обратную матрицу	Порядка p^3 операций

На практике матрицу A раскладывают на более простые части и решают преобразованную задачу. Два таких метода — QR и SVD.



QR-разложение: удобная система уравнений

QR представляет A как произведение двух матриц: $A = Q \cdot R$.

Буква Q здесь — название матрицы, а не критерия ошибки $Q(w)$.

Часть	Простой смысл
Q	Меняет систему координат, сохраняя расстояния
R	Треугольная матрица: веса находим от последнего к первому

Получаем те же МНК-веса при независимых столбцах.

Явно вычислять $(A^T A)^{-1}$ не требуется.

SVD: какие направления различают данные

SVD — сингулярное разложение. Оно выделяет направления изменения весов. Сингулярное число показывает, насколько меняется вектор прогнозов Aw при изменении весов на единицу в соответствующем направлении.

Сингулярное число	Что это означает
Равно нулю	Меняем веса в этом направлении, а прогнозы не меняются
Очень мало	Данные слабо различают веса, решение чувствительно к шуму

На основе SVD можно решить МНК и при зависимых столбцах.
Из равноценных решений выбираем веса с наименьшей суммой квадратов.

Точный дубликат проще убрать. Численный метод сам по себе не делает признаки информативнее.




Обработка признаков

04

Преобразования числовых признаков
One-hot encoding и взаимодействия
Масштабирование и пропуски

Рисунок ошибок подсказывает новый признак

Построили прямую по расстоянию и посмотрели её ошибки на каждом заказе.



$r > 0$: время завышено.

$r < 0$: время занижено.

В середине прямая завышает время,
по краям занижает: видна кривизна.

Добавим x^2 , чтобы модель
могла описать изгиб.

Изгиб — повод проверить новую модель на отложенных данных. Сам по себе он не гарантирует улучшения.

Степени, логарифмы и другие преобразования

Вместо исходного x или вместе с ним можно добавить преобразования.
Здесь $x \geq 0$: например, расстояние или число активных заказов.

Признак	Какую зависимость позволяет описать
x^2	Изгиб: эффект следующей единицы может усиливаться
$\log(1 + x)$	Замедляющийся рост; допустим $x = 0$
$\sqrt{x}$	Ещё один вариант замедляющегося роста

$$a(x) = w_0 + w_1x + w_2x^2 + w_3\log(1 + x)$$

Линейность относится к весам. Признаки задают допустимую форму зависимости и могут взаимодействовать.

One-hot encoding: район в линейной модели

Район — категория. Введём индикаторы: $b_2 = 1$ для Центра, $b_3 = 1$ для Юга. Для остальных районов соответствующий индикатор равен 0.

Район	b_2	b_3	Добавка к прогнозу
Север	0	0	0 минут
Центр	1	0	3 минуты
Юг	0	1	7 минут

$$a(x) = 12 + 4s + 3b_2 + 7b_3$$

Север — базовая категория. При одинаковом расстоянии Центр добавляет 3 минуты, Юг — 7.



Почему достаточно $k - 1$ индикаторов

Для трёх районов полный one-hot дал бы три столбца.

В каждой строке ровно одна единица:

$$b_{\text{Север}} + b_{\text{Центр}} + b_{\text{Юг}} = 1$$

Но столбец единиц уже есть в A для свободного члена.

Получается зависимость столбцов, как в примере с километрами и метрами.

Убираем индикатор Севера. Его легко восстановить: Север — это $(0, 0)$.

Для k категорий оставляем $k - 1$ индикаторов и свободный член.

Взаимодействие: разная цена километра

Один индикатор района меняет только добавку ко времени.

Чтобы километр в Центре стоил больше минут, добавим произведение $s \cdot b$.

$$a(x) = 12 + 4s + 3b + 2sb$$

Район	Подставляем b	Модель	Ещё 1 км
Север	$b = 0$	$12 + 4s$	+4 мин
Центр	$b = 1$	$15 + 6s$	+6 мин

s — расстояние, b — индикатор Центра. Признак $s \cdot b$ позволяет наклону зависеть от района.

Интервальные признаки

Связь времени доставки с текущей нагрузкой может быть нелинейной. Закодируем число активных заказов n через интервалы.

$$b_j(x) = 1\{t_{j-1} \leq n < t_j\}$$

Активных заказов	$n < 10$	$10 \leq n < 20$	$n \geq 20$
Индикаторы	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)

Пороги здесь заданы для примера. С intercept оставляем один интервал базовым.



Масштабирование числовых признаков

$$z_j = \frac{x_j - \mu_j}{\sigma_j}$$

μ_j — среднее, σ_j — стандартное отклонение признака на train.

Те же значения используем при обработке новых данных.

В МНК с intercept обратимое масштабирование меняет веса, но сохраняет множество прогнозов. Оно устраняет различие масштабов, однако не устраняет линейную зависимость столбцов.

При $\sigma_j = 0$ признак константный; при наличии intercept его можно убрать.



Пропуски и применение преобразований

Шаг	Пример для нагрузки сервиса
Обработать пропуск	Заменить неизвестную нагрузку медианой train
Сохранить информацию	Добавить индикатор «нагрузка неизвестна»
Зафиксировать параметры	Сохранить медиану, масштабы, категории и пороги
Применить к новым заказам	Выполнить те же преобразования без переоценки по новым данным

После обработки получаем числовую матрицу F .

Добавляем столбец единиц и обучаем уже изученный МНК.



Интерпретация и проверка модели

05

Смысл коэффициентов модели
Структура невязок
Качество на отложенных данных

Интерпретация коэффициентов

$$a(x) = 13.3 + 3.9x$$

3,9 мин/км — изменение прогноза при увеличении расстояния на 1 км.

13,3 мин — значение прямой при $x = 0$. В выборке нет таких маршрутов, поэтому этот прогноз требует осторожной интерпретации.

Коэффициент описывает зависимость в модели.

Причинный эффект изменения маршрута из него не следует.



Проверка обученной регрессии

Проверка	Что она выявляет
Отложенная выборка или кросс-валидация	Помогли ли новые признаки по выбранной метрике
Невязки по районам и нагрузке	Где модель систематически завышает или занижает время
Веса при изменении выборки	Есть ли неустойчивость и компенсирующие коэффициенты
Диапазон новых признаков	Не перешли ли мы от интерполяции к экстраполяции

Кросс-валидация повторяет обучение на нескольких разбиениях. Для доставки сохраняем порядок времени; обработку признаков обучаем заново внутри каждого train.



Линейная регрессия в Python

06

LinearRegression в scikit-learn

OLS и статистический отчёт в statsmodels

Прогнозирование и анализ коэффициентов



LinearRegression: обучить и получить прогноз

Повторим расчёт для пяти доставок. F содержит признаки без столбца единиц. LinearRegression по умолчанию обучает свободный член сама.

```
from sklearn.linear_model import LinearRegression
```

```
F = [[1], [2], [3], [4], [5]]
```

```
y = [18, 20, 25, 29, 33]
```

```
model = LinearRegression().fit(F, y)
```

```
model.predict([[3.5]])
```

Результат: `intercept_ = 13,3; coef_ = [3,9]`.

Для 3,5 км прогноз равен 26,95 минуты, как при ручном расчёте.

statsmodels: коэффициенты и их неопределённость

Используем те же F и y . В матричном интерфейсе OLS столбец единиц добавляем явно: $A = [1 \ F]$.

```
import statsmodels.api as sm
A = sm.add_constant(F, has_constant="add")
result = sm.OLS(y, A).fit()
print(result.summary())
```

В отчёте	Что читаем
coef	Оценки коэффициентов: 13,3 и 3,9
std err, интервалы, p-value	Неопределённость оценок и проверка нулевого коэффициента
R-squared	R^2 на данных, использованных при обучении

Интервалы и p-value зависят от предпосылок о данных. Они не доказывают причинность.

Две библиотеки, одна задача МНК

	scikit-learn	statsmodels
Основная работа	Прогнозы, Pipeline, проверка качества	Анализ коэффициентов и статистический отчёт
Свободный член	fit_intercept=True по умолчанию	Добавить в матричном API
Результат	predict, coef_, intercept_	params, summary, интервалы

При одинаковых признаках, свободном члене и единственном решении получаем одинаковые МНК-веса с точностью до округления.

Качество на новых данных проверяем отдельно в обоих случаях. Высокий R^2 на train этого не заменяет.



Линейная регрессия: полный путь

Шаг	Что получаем
1. Подготовить признаки	Числовая матрица F ; затем $A = [1 \ F]$
2. Обучить МНК	Решаем задачу численно; QR/SVD учитывают структуру A
3. Интерпретировать результат	Смысл коэффициентов и структура невязок
4. Проверить модель	Невязки, интерпретация и ошибка на новых данных

Обработка признаков задаёт допустимые зависимости.

МНК выбирает лучшую из них по квадратичному критерию на train.



Вопросы



Регрессия к среднему

Название связано с работой Фрэнсиса Гальтона 1886 года о росте родителей и их взрослых детей.

Наблюдение	Средний результат в группе
Очень высокие родители	Рост детей обычно менее далеко от среднего роста
Очень низкие родители	Рост детей обычно тоже ближе к среднему

Речь о статистической закономерности в группах, а не о каждом ребёнке.

Современная регрессия в ML — предсказание числовой целевой переменной.