



Национальный Исследовательский
Университет «Высшая Школа Экономики»

2026

Градиентное обучение, линейная классификация

Лекция 4



Содержание

- 1 Новый метод SAG и выбор шага
- 2 Методы Momentum, AdaGrad, RMSprop и Adam
- 3 Линейная классификация и отступ
- 4 Потери и проверка качества классификации



SAG и выбор шага

01

Вводим SAG с нуля
Разбираем выбор и изменение шага



Что уже знаем: GD, mini-batch и SGD

В прошлой лекции мы меняли веса, двигаясь против градиента ошибки.
Разные методы отличаются тем, по каким объектам считают направление.

Метод	Градиент для одного шага	Особенность
GD	Вся выборка	Точный, но дорогой шаг
Mini-batch	Небольшая порция	Компромисс по стоимости и шуму
SGD	Один объект	Дешёвый и шумный шаг



Вопрос: что не так с одним градиентом SGD

Можно ли уменьшить шум SGD, не пересчитывая всю выборку?



Новый метод: SAG

SAG означает Stochastic Average Gradient.

Идея: сохранять последний вычисленный градиент каждого объекта.

Объект 1	Объект 2	Объект 3
Свой сохранённый градиент	Свой сохранённый градиент	Свой сохранённый градиент

На шаге обновляем одну ячейку. Движемся против среднего всех сохранённых градиентов.



SAG: что делаем на каждой итерации

Перед началом создаём по ячейке z_i на объект и записываем нули.

1. Случайно выбираем один объект.
2. Считаем его градиент при текущих весах и заменяем z_i .
3. Усредняем записи и обновляем веса.

$$g = \frac{1}{\ell} \sum_{i=1}^{\ell} z_i$$

$$w^{new} = w - \eta g$$



SAG: первые два шага с пустой памятью

Три объекта, один вес $w = 2$, $\eta = 0,1$.

Пока объект не выбран, в его ячейке хранится 0.

Состояние	z_1	z_2	z_3	Среднее g	Вес w
До обучения	0	0	0	0	2
Выбрали объект 1	-6	0	0	-2	2,2
Выбрали объект 2	-6	+3	0	-1	2,3


На втором шаге запись z_1 используем без пересчёта.

Как длина шага меняет результат

$Q(w) = w^2 / 2$. На каждом шаге градиент равен текущему w .

Делаем 3 шага по правилу $w_{k+1} = (1 - \eta)w_k$. Чёрная точка: старт $w_0 = 2$.


$\eta = 0,2$



Медленно приближаемся

$w: 2 \ 1,6 \ 1,28 \ 1,024$


$\eta = 0,8$



Быстро приближаемся

$w: 2 \ 0,4 \ 0,08 \ 0,016$

$\eta = 2,2$



Уходим от минимума

$w: 2 \ -2,4 \ 2,88 \ -3,456$



Как выбирают длину шага

В GD, mini-batch и SGD коэффициент η можно задавать по-разному.

Подход	Что делаем	Пример
Постоянный шаг	Выбираем η и сохраняем его	$\eta = 0,1$ на всех шагах
Расписание	Меняем η в заданные моменты	Первые 5 эпох: 0,1 Затем 5 эпох: 0,05
По изменению ошибки	Пробуем шаг. Если ошибка выросла, уменьшаем η и пробуем ещё раз.	Сейчас ошибка равна 10. $\eta = 0,1$: ошибка 12. Отклоняем. $\eta = 0,05$: ошибка 8. Принимаем.

Убывающий шаг в SGD: правила и примеры

Шаг уменьшают, чтобы ослабить случайные колебания градиента.

$$\sum_{k=1}^{\infty} \eta_k = \infty$$

Сумма шагов не ограничена:
можно продолжать движение.

$$\sum_{k=1}^{\infty} \eta_k^2 < \infty$$

Сумма квадратов конечна:
влияние шума ослабевает.

Два примера, которые удовлетворяют обоим условиям:

$$\eta_k = \frac{0.1}{k}$$

k = 1, 2, 3, 4:

0,100 0,050 0,033 0,025

$$\eta_k = \frac{0.1}{k^{0.75}}$$

k = 1, 2, 3, 4:

0,100 0,059 0,044 0,035



Методы изменения шага


02

Инерция накапливает направление

Адаптивные методы учитывают масштаб градиентов

Как пойдёт градиентный спуск из этой точки?


Серые линии соединяют точки с одинаковой ошибкой.



Чёрная точка: старт. Зелёная точка: минимум.

Так идут 12 шагов градиентного спуска

Каждая синяя точка показывает новое положение весов.



$Q = 0,5w_1^2 + 5w_2^2$. Коэффициент $\eta = 0,17$.



Momentum: шаг с инерцией

Новый шаг учитывает текущий градиент и часть прошлого шага.
Если направления согласованы, движение ускоряется.


$$h_k = \alpha h_{k-1} + \eta_k \nabla Q(w^{(k-1)})$$

$$w^{(k)} = w^{(k-1)} - h_k$$


GD и Momentum: сравнение траекторий

Оба метода стартуют из чёрной точки и делают 12 шагов.
Зелёная точка: минимум. $\eta = 0,17$. Для Momentum $\alpha = 0,5$.

Обычный GD



Momentum



AdaGrad: отдельный масштаб для каждого веса

Если градиент по весу часто велик, AdaGrad уменьшает его будущие шаги.
Для редко активного признака шаг убывает медленнее.

$$G_{k,j} = G_{k-1,j} + (\nabla Q(w^{(k-1)})_j)^2$$

$$w_j^{(k)} = w_j^{(k-1)} - \frac{\eta}{\sqrt{G_{k,j} + \varepsilon}} \nabla Q(w^{(k-1)})_j$$



AdaGrad: одинаковый градиент у двух признаков

На пятом шаге градиент по каждому из двух весов равен 1.
Но история этих градиентов разная.

Признак	Градиенты на шагах 1–4	Градиент на шаге 5
Частый	1, 1, 1, 1	1
Редкий	1, 0, 0, 0	1

Будет ли AdaGrad одинаково менять эти веса на пятом шаге?

AdaGrad: от истории градиентов к новому шагу

Сейчас у обоих весов $g = 1$ и $\eta = 1$. Размер шага зависит от того, сколько уже накоплено в сумме G .

Признак	Квадраты градиентов за 5 шагов	Сумма G	Новый шаг
Частый	$\boxed{1} + \boxed{1} + \boxed{1} + \boxed{1} + \boxed{1}$	$= 5$	$-\frac{1}{\sqrt{5}} \approx -0.45$
Редкий	$\boxed{1} + \boxed{0} + \boxed{0} + \boxed{0} + \boxed{1}$	$= 2$	$-\frac{1}{\sqrt{2}} \approx -0.71$

Больше накоплено G : меньше изменение при том же градиенте.

RMSprop: накопление градиентов и шаг

Для одного веса g_k обозначает текущий градиент.
Старые квадраты градиентов постепенно теряют влияние.

1. Обновляем средний квадрат

Сохраняем долю β от прошлого G
и добавляем долю $(1 - \beta)$ от нового g^2 .

$$G_k = \beta G_{k-1} + (1 - \beta) g_k^2$$

Например, $\beta = 0,9$:
90% прошлого G и 10% нового g^2 .

2. Вычисляем шаг по весу


При том же g_k большое G_k уменьшает шаг.
Если G_k снижается, шаг может вырасти.

$$\Delta w_k = -\eta \frac{g_k}{\sqrt{G_k + \varepsilon}}$$

$\varepsilon > 0$ защищает от деления на ноль.

RMSprop: что остаётся от старого градиента

Однажды получили $g = 4$, значит $g^2 = 16$. Отследим только его вклад в G .
Новые градиенты тоже добавляют свои вклады, но здесь они не показаны.



AdaGrad сохраняет 16. RMSprop на каждом следующем шаге оставляет половину.

Adam: направление и размер шага

Adam сочетает идеи Momentum и RMSprop.

Для каждого веса он хранит два скользящих средних.

Среднее градиентов m

Сглаживает колебания направления.

Один случайный градиент меньше
влияет на следующий шаг.

Среднее квадратов v

Учитывает размер градиентов.

Чем оно больше, тем сильнее
уменьшаем шаг по этому весу.

$$w_{new} = w - \eta \frac{m^c}{\sqrt{v^c} + \varepsilon}$$

m^c и v^c : средние с поправкой на нулевые начальные значения.



Какую задачу решает каждый метод

Метод	Что хотим исправить	За счёт чего
Momentum	Направление шага колеблется	Учитываем прошлые направления
AdaGrad	У признаков разная история градиентов	Свой накопленный масштаб для каждого веса
RMSprop	Старые большие градиенты уменьшают шаг надолго	Забываем старые квадраты градиентов
Adam	Нужны и устойчивое направление, и адаптивный масштаб	Сочетаем два скользящих средних

Это разные способы строить шаг. Подходящий метод выбираем по обучению и validation.



Линейная классификация

03

Скор и прямая граница решений
Отступ объекта и доля ошибок



Бинарная задача: опоздает ли доставка

При подтверждении заказа хотим предсказать, займёт ли доставка больше 30 минут. Признаки известны уже в этот момент.

Ответ	Смысл
$y = +1$	Доставка заняла больше 30 минут
$y = -1$	Доставка заняла не больше 30 минут



Линейный скор и правило решения

Каждый признак вносит в скор свой вклад. Положительный скор означает прогноз «опоздает», отрицательный «вовремя».

$$f_w(x) = w_0 + \sum_{j=1}^d w_j \cdot x_j$$

$$a_w(x) = \text{sign}(f_w(x))$$

Пример: $f(x) = -7 + \text{расстояние} + \text{нагрузка}$.


При $f(x) = 0$ ответ считаем ошибкой.

Граница решений на двух признаках

Учебные заказы. Выше прямой модель предсказывает опоздание, ниже прямой: доставку вовремя. Граница: расстояние + нагрузка = 7.

Оранжевые точки: опоздала (+1)

Синие точки: вовремя (-1)





Отступ объекта

Умножим скор на правильную метку $y \in \{-1, +1\}$.
Знак результата сразу показывает, верно ли решение.

$$M_i = y_i f_w(x_i)$$

Отступ	Интерпретация
$M_i > 0$	Класс определён верно
$M_i < 0$	Класс определён неверно
$M_i = 0$	Объект лежит на границе



Отступ: три учебных объекта

Для одного и того же классификатора сравним знак и величину M .

Объект	Метка y	Скор $f(x)$	Отступ $M = y f(x)$	Результат
A	+1	+2,0	+2,0	Верно
B	-1	+0,3	-0,3	Ошибка
C	+1	-2,0	-2,0	Большая ошибка



Доля ошибок как критерий


Естественный критерий классификации считает неверные ответы.

$$Q_{0/1}(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} [M_i \leq 0]$$

Функция $[M \leq 0]$ кусочно постоянна. Её градиент почти всюду равен нулю, поэтому обычный GD не получает полезного направления.

0–1 потеря: ступенька в нуле

При $M \leq 0$ ошибка стоит 1. При $M > 0$ стоит 0. Малый сдвиг вдали от нуля не меняет штраф.





Потери и качество классификации

04

Замена неудобной 0–1 потери
Accuracy и цена ошибок при дисбалансе



Вопрос: чем заменить ступеньку

Один объект имеет отступ $M = -2$.

Другой находится рядом с границей: $M = -0,1$.

0–1 потеря равна 1 для обоих. Как показать алгоритму, какая ошибка хуже?



Заменяем 0–1 потерю

Вместо скачка в нуле берём функцию от отступа, которая меняется постепенно и даёт направление для оптимизации.

Отступ M	0–1 потеря	Желаемое поведение суррогата
Сильная ошибка	1	Большой штраф
Рядом с границей	Зависит от знака	Заметный штраф
Уверенно верно	0	Малый штраф



Четыре функции потерь от отступа


Потеря	Формула $L(M)$	Свойство
Экспоненциальная	$\exp(-M)$	Сильно наказывает большие ошибки
Сигмоидальная	$\frac{2}{1 + \exp(M)}$	Ограничена, но невыпукла
Логистическая	$\ln(1 + \exp(-M))$	Гладкая и выпуклая
Hinge	$\max(0, 1 - M)$	Нулевой штраф при $M \geq 1$

Логистическая потеря и hinge


Чёрная линия: 0–1 потеря. Цветная: потеря для обучения.

У обеих панелей одинаковые оси, поэтому высоты можно сравнивать.

Логистическая: плавно убывает




Hinge: равна нулю при $M \geq 1$




Потеря при большом отрицательном отступе

При $M = -2$ экспоненциальная потеря равна 7,39, сигмоидальная 1,76.
Экспонента растёт без границы, сигмоидальная стремится к 2.

Экспоненциальная: шкала 0–8



Сигмоидальная: шкала 0–2





Как потери относятся к ошибке

При одинаковой доле ошибок модели могут иметь разные отступы.
Потери различают большой отрицательный отступ и точку у границы.

M	0–1	$\exp(-M)$	$\ln(1 + \exp(-M))$	$\max(0, 1-M)$
-2	1	7,39	2,13	3
0	1	1,00	0,69	1
+1	0	0,37	0,31	0
+2	0	0,14	0,13	0

Обучение линейного классификатора

Выбираем веса, минимизируя среднюю потерю на train.

Штраф за большие веса можно добавить отдельно.

$$J(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} L(y_i f_w(x_i)) + \lambda \sum_{j=1}^d w_j^2$$



Что оптимизируем на трёх объектах

Вернёмся к объектам А, В и С. Выбрали логистическую потерю.
Пока считаем только среднюю потерю, без регуляризации.

Объект	Отступ М	Правильный класс?	$\ln(1 + \exp(-M))$
А	+2,0	Да	0,127
В	-0,3	Нет	0,854
С	-2,0	Нет	2,127

Средняя потеря $\approx 1,036$. Доля ошибок = 2/3.



Accuracy: доля правильных ответов

$$\text{accuracy} = \frac{1}{\ell} \sum_{i=1}^{\ell} [a_w(x_i) = y_i]$$

Если из 100 заказов правильно классифицированы 92,
accuracy равна 0,92, или 92%.



Accuracy при редком положительном классе

Среди 100 доставок только 5 опоздали. Модель, которая всегда предсказывает «вовремя», правильно отвечает для 95 заказов.

Фактический класс	Сколько объектов	Правильно найдено
Вовремя	95	95
Опоздала	5	0

Accuracy = 95%, но все 5 опозданий пропущены.



Абсолютное и относительное улучшение

Относительное снижение ошибки нужно читать вместе с исходной частотой ошибки и абсолютным изменением.

Доля ошибок	Снижение в п. п.	Относительное снижение
с 20% до 10%	10	50%
с 50% до 25%	25	50%
с 0,1% до 0,01%	0,09	90%



Как сравнивать классификаторы

1. Сначала определяем, какие ошибки важны для задачи.
2. Выбираем метрику и правило разбиения до подбора модели.
3. Сравниваем варианты на validation.
4. После выбора один раз считаем качество на test.



Итоги

Раздел	Что получили
Градиентные методы	SAG хранит градиенты объектов. Momentum учитывает прошлые шаги. AdaGrad, RMSprop и Adam подстраивают шаг для каждого веса.
Классификация	Линейный скор задаёт границу. Отступ показывает, верно ли классифицирован объект.
Обучение и оценка	Потеря от отступа помогает обучать модель. При оценке ассигасу учитываем баланс классов.



Вопросы