

Национальный Исследовательский
Университет «Высшая Школа Экономики»

2026

SVM и логрег

Лекция 6

Содержание

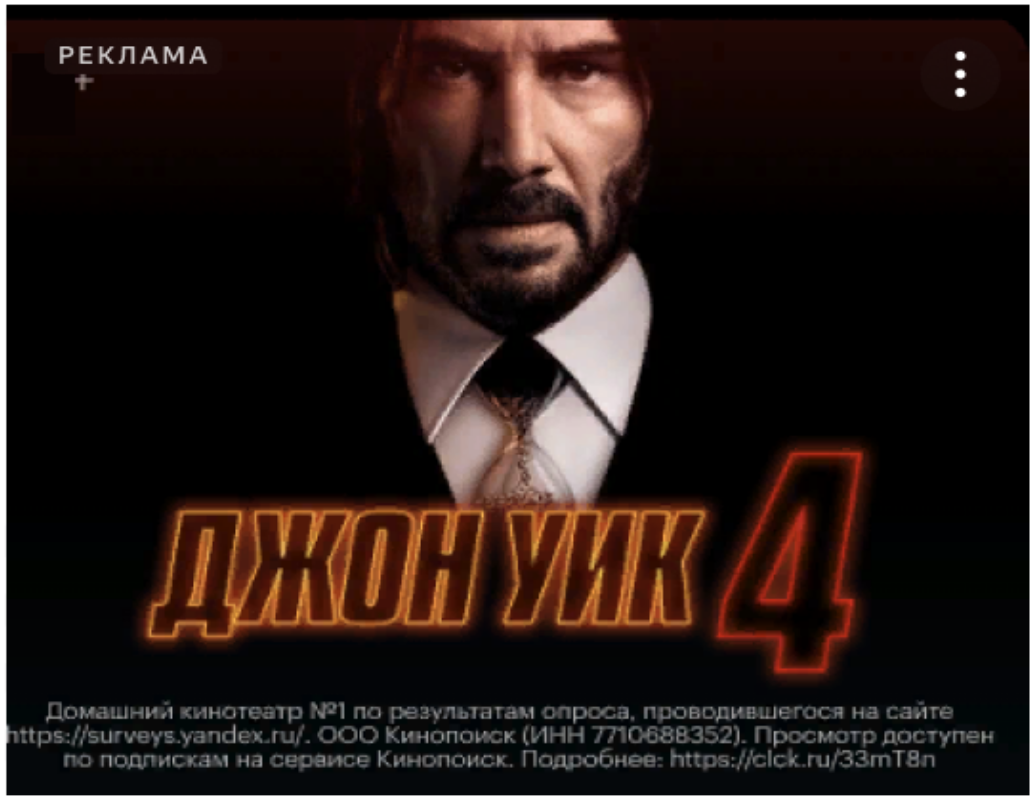
1 Вероятность клика: задача и данные

2 Логистическая модель и смысл весов

3 Log loss, обучение и регуляризация

4 SVM: отступ, hinge loss и ядра

Кликнет ли пользователь по баннеру?



Пример баннера: Рекламная сеть Яндекса

Объект: один возможный показ

Признаки известны до показа: интересы пользователя, баннер, страница и устройство.

После показа наблюдаем ответ:
$y = 1$, если был клик,
$y = 0$, если клика не было.

До показа нужна оценка
$p = P(\text{клик} \mid \text{признаки})$.

Как вероятность помогает выбрать баннер

За клик получаем c рублей. Доход за показ обозначим V.
Без клика V = 0. Выбираем один из трёх баннеров. Числа учебные.

$$\mathbb{E}[V] = p \cdot c$$

Баннер	Вероятность клика p	Доход за клик c	В среднем за показ
A	0,10	10 ₽	1 ₽
B	0,05	40 ₽	2 ₽
C	0,02	50 ₽	1 ₽

Как понимать вероятность клика

Если вероятность клика равна p, за n показов ожидаем n · p кликов.
Фактическое число кликов может отличаться. Учебные примеры:

Вероятность p	Показов n	Ожидаем кликов	Возможный результат
0,1	10	1	0 кликов
0,1	1000	100	106 кликов
0,5	1000	500	493 клика
0,9	1000	900	887 кликов

Прогноз 0,1 не обещает ровно один клик на каждые десять показов.

Дальше в курсе разберём калибровочную кривую: как сопоставить прогнозы модели с фактической долей кликов в группах показов.

Скор, вероятность и класс

Линейный скор может принимать любые вещественные значения.

$$z = b + w_1 x_1 + \ldots + w_d x_d$$

Шаг	Пример	Что получили
Линейная модель	z = –2	Скор для ранжирования
Преобразование скора	p ≈ 0,12	Оценку вероятности клика
Сравнение с порогом 0,5	ŷ = 0	Прогноз класса «нет клика»

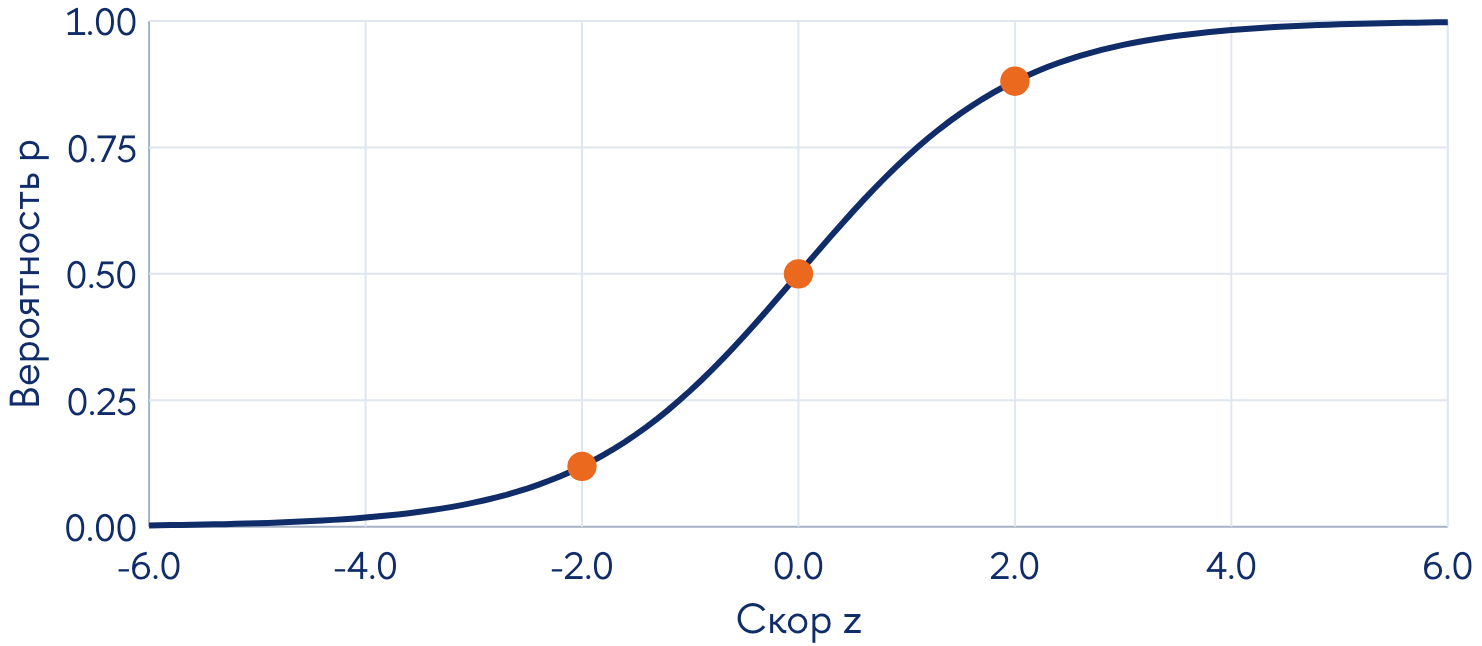
Логистическая модель

02

Сигмоида и расчёт вероятности
Шансы, логарифм шансов и веса признаков

Сигмоида переводит скор в вероятность

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}$$



$z = -2 \rightarrow p \approx 0{,}12$

$z = 0 \rightarrow p = 0{,}50$

$z = 2 \rightarrow p \approx 0{,}88$

Расчёт вероятности для одного показа

x_1: число посещений сайта рекламодателя за последние 7 дней.
x_2: показ с телефона (1) или с компьютера (0). Веса учебные.

$$z = -2 + 0.7x_1 - 0.5x_2$$

Два посещения, показ с телефона: $x_1 = 2$, $x_2 = 1$.

$$z = -2 + 0.7 \cdot 2 - 0.5 \cdot 1 = -1.1$$

$$p = \frac{1}{1 + e^{1.1}} \approx 0.25$$

Вероятность и шансы клика

Вероятность оцениваем долей кликов среди всех показов.
Шансы оцениваем отношением числа кликов к числу показов без клика.

Из 100 показов	Вероятность клика	Шансы клика
20 кликов, 80 без клика	20 / 100 = 0,2	20 / 80 = 1 / 4
50 кликов, 50 без клика	50 / 100 = 0,5	50 / 50 = 1
80 кликов, 20 без клика	80 / 100 = 0,8	80 / 20 = 4

$$\text{odds} = \frac{p}{1-p}$$

Шансы 1 : 4 означают один клик на четыре показа без клика.

Зачем брать логарифм шансов

Шансы всегда положительны. Их натуральный логарифм ln может быть любым числом, как и линейный скор z.

p	Шансы p / (1 – p)	Логарифм шансов
0,2	1 / 4	ln(1 / 4) ≈ –1,386
0,5	1	ln 1 = 0
0,8	4	ln 4 ≈ 1,386

Предположение логистической модели:

$$\ln \frac{p}{1-p} = z = b + w^\top x \quad \Longleftrightarrow \quad p = \sigma(z)$$

Вес признака: скор, шансы, вероятность

В нашей модели вес при числе посещений сайта равен 0,7.
Сравним 2 и 3 посещения, остальные признаки оставим прежними.

Что считает модель	2 посещения	3 посещения
Скор z	–1,1	–0,4: прибавили 0,7
Шансы e^z	≈ 0,333	≈ 0,670: умножили на $e^{0.7} \approx 2$
Вероятность p	≈ 0,250	≈ 0,401

При увеличении признака на 1 шансы умножаются на e^w.
Вероятность не удваивается: в примере она выросла с 25% до 40%.

Обучение логистической регрессии

03

Правдоподобие и log loss
Градиентный спуск и регуляризация

Вероятность фактического ответа

Для одного показа модель предсказала вероятность клика p = 0,8.

Что произошло	Вероятность этого ответа
Был клик: y = 1	p = 0,8
Клика не было: y = 0	1 – p = 0,2

Подбираем веса так, чтобы наблюдавшиеся ответы были более вероятны.

Правдоподобие на двух показах

Первый показ закончился кликом, второй без клика.
Сравним два набора весов по вероятности этих двух ответов.

Набор весов	p_1, был клик	p_2, без клика	Вероятности ответов
A	0,9	0,2	0,9 и 1 – 0,2 = 0,8
B	0,3	0,8	0,3 и 1 – 0,8 = 0,2

Считаем ответы независимыми при заданных признаках и весах.

$$\mathcal{L}_A = 0.9 \cdot 0.8 = 0.72, \qquad \mathcal{L}_B = 0.3 \cdot 0.2 = 0.06$$

Логарифм правдоподобия

Ищем веса, при которых правдоподобие максимально.
Логарифм не меняет положение максимума, а произведение заменяет суммой.

$$\ln(0.9 \cdot 0.8) = \ln 0.9 + \ln 0.8 \approx -0.329$$

Критерий	Набор A	Набор B	Что выбираем
Правдоподобие	0,72	0,06	Больше
Логарифм правдоподобия	–0,329	–2,813	Больше
Минус логарифм	0,329	2,813	Меньше

Log loss для клика и отсутствия клика

Потеря равна минус логарифму вероятности фактического ответа.

Факт	Потеря	Пример при p = 0,8
Был клик: y = 1	–ln p	–ln 0,8 ≈ 0,223
Не было клика: y = 0	–ln(1 – p)	–ln 0,2 ≈ 1,609

$$L(y, p) = -y \ln p - (1 - y) \ln(1 - p)$$

Средняя потеря на выборке

Вычисляем log loss для всех показов и берём среднее.

Показ	Факт y	Прогноз p	Log loss
A	1	0,90	0,105
B	0	0,80	1,609
C	1	0,60	0,511
D	0	0,10	0,105

$$Q(w,b) = \frac{1}{n}\sum_{i=1}^{n} L(y_i, p_i) \approx 0.583$$

Градиент log loss после сигмоиды

Для градиентного спуска найдём производную log loss.
Подставим p = σ(z) и продифференцируем по скору z:

$$\frac{dL}{dz} = p - y$$

Факт и прогноз	Производная	Чтобы уменьшить потерю
Клик, но p = 0,2	0,2 – 1 = –0,8	Увеличиваем скор z
Нет клика, но p = 0,8	0,8 – 0 = 0,8	Уменьшаем скор z

Градиентный спуск по весам

При обучении меняем веса w и свободный член b.

Для каждого показа считаем p_i и разность между прогнозом и ответом $p_i - y_i$.

$$\frac{\partial Q}{\partial w_j} = \frac{1}{n}\sum_i (p_i - y_i)x_{ij}$$

$$\frac{\partial Q}{\partial b} = \frac{1}{n}\sum_i (p_i - y_i)$$

$$w_j \leftarrow w_j - \eta\frac{\partial Q}{\partial w_j}, \qquad b \leftarrow b - \eta\frac{\partial Q}{\partial b}$$

L2-регуляризация ограничивает веса

Пример: x = (–2, –1, 1, 2), y = (0, 0, 1, 1), b = 0. Классы разделимы.
Log loss убывает при росте w. Добавим штраф 0,05 · w².

Вес w	Log loss	Штраф 0,05 · w²	Сумма
0,75	0,294	0,028	0,322
2	0,073	0,200	0,273
5	0,003	1,250	1,253

$$Q_\lambda = Q + \frac{\lambda}{2}\sum_j w_j^2$$

λ задаёт силу штрафа. Здесь λ = 0,1.
Свободный член b не штрафуем.

Метод опорных векторов

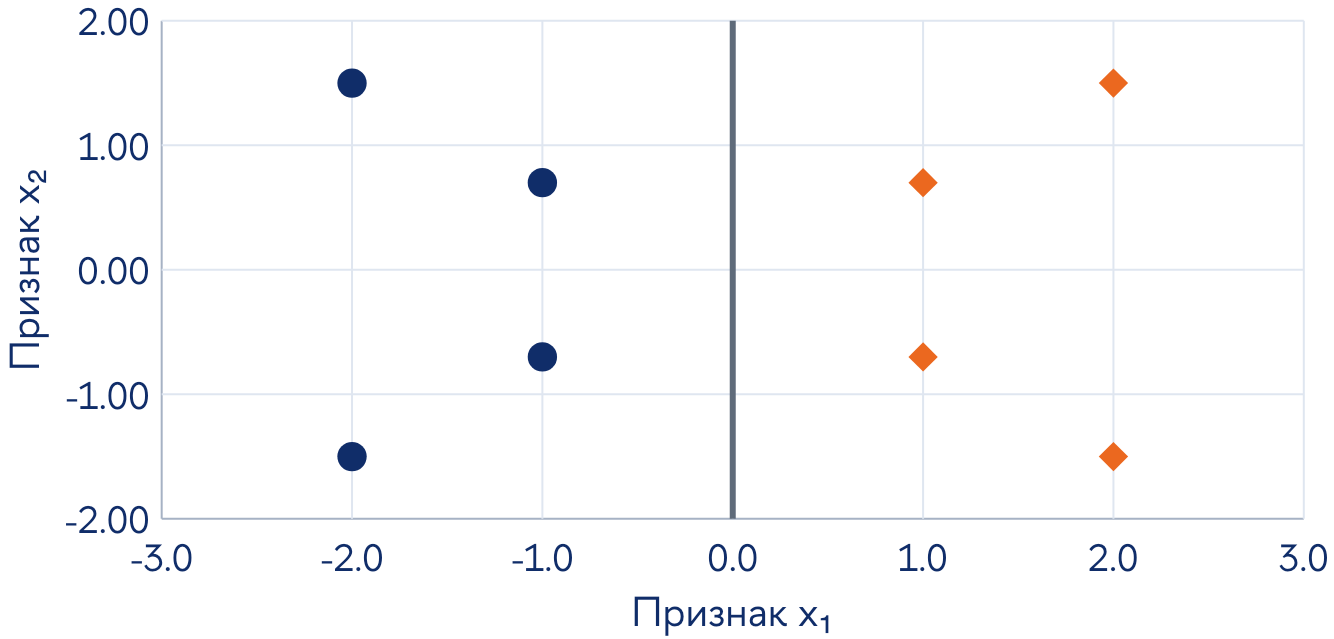
04

Выбор разделяющей прямой и расстояние до объектов
Постановка SVM, нарушения отступа и hinge loss

Линейная граница между классами

Теперь обозначим классы числами –1 и +1: $s = 2y - 1$.

Считаем прежний линейный скор $z = w^T x + b$ и берём его знак.



Синий круг: класс –1

Оранжевый ромб: класс +1

$z < 0$: прогноз –1

$z > 0$: прогноз +1

Граница проходит там, где $z = 0$.

На рисунке $z = x_1$.

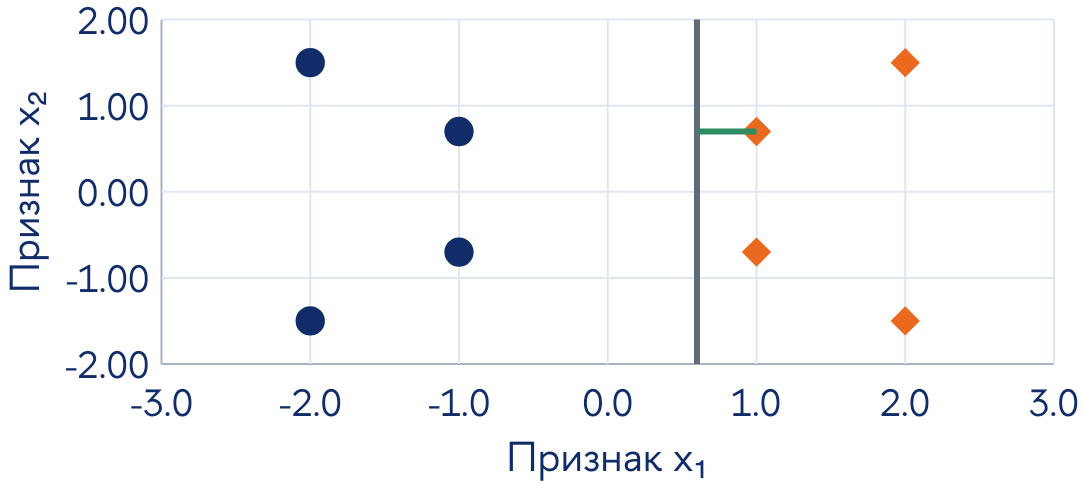
Граница: $x_1 = 0$.

Выбор между двумя разделяющими прямыми

Обе прямые верно разделяют все восемь объектов.

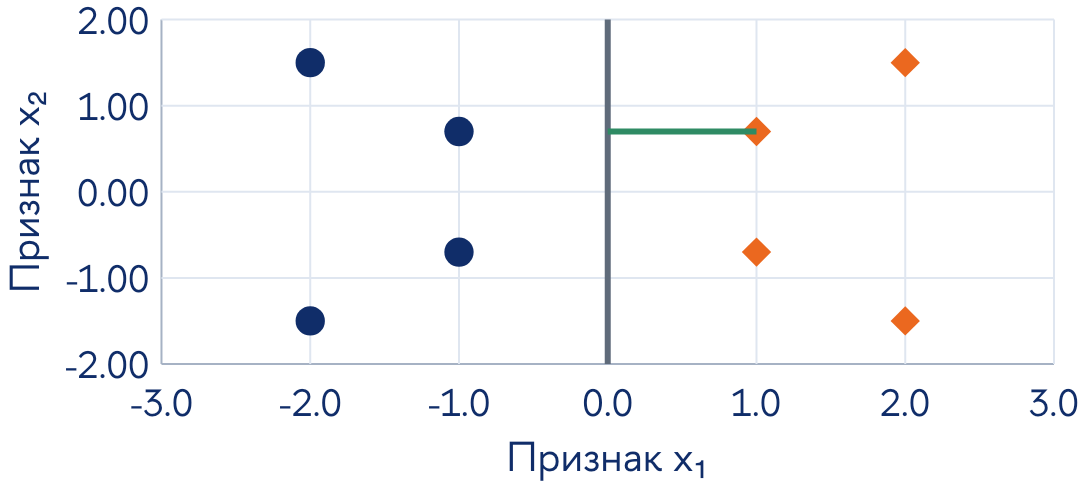
Сравним расстояние от прямой до ближайшего объекта.

Граница $x_1 = 0{,}6$



Зелёный отрезок: расстояние 0,4.

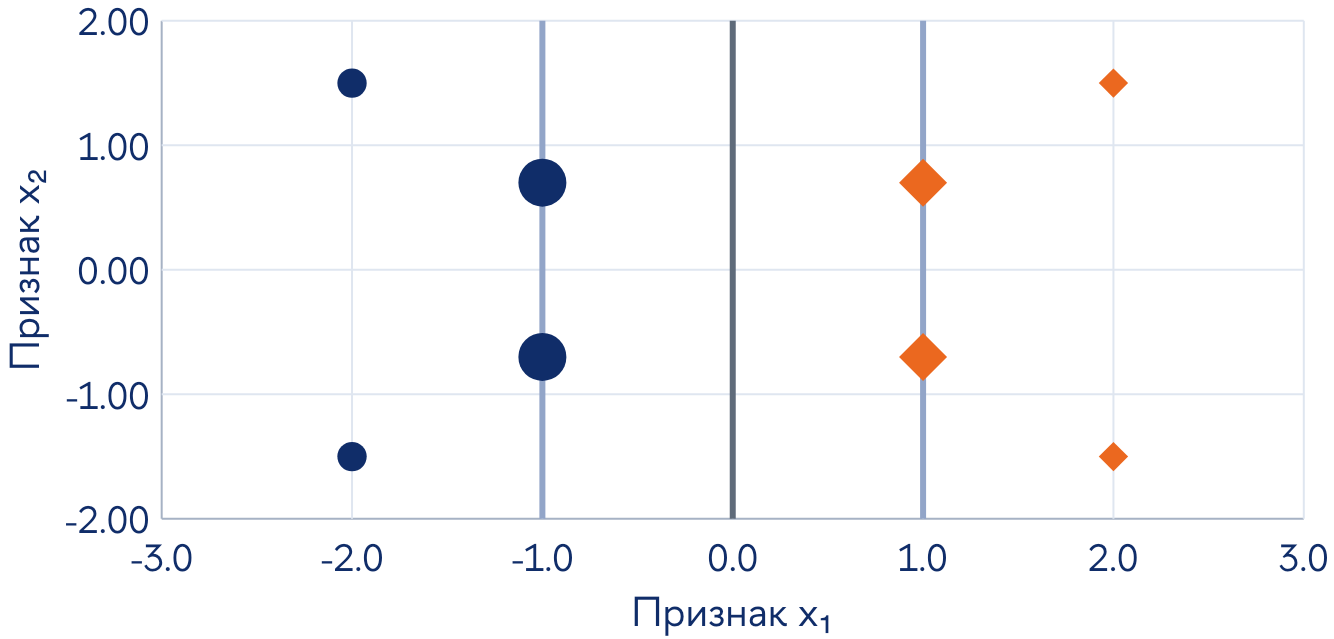
Граница $x_1 = 0$



Зелёный отрезок: расстояние 1.

Разделяющая полоса и опорные векторы

SVM выбирает границу с максимальным расстоянием до ближайших объектов.
Вокруг неё получается самая широкая пустая полоса.



Ближайшие объекты ограничивают ширину полосы. Их называют опорными векторами.

Светлые линии: края полосы.
Крупные точки: опорные.
Вектор объекта: (x_1, x_2).

До каждого края: 1.
Полная ширина полосы: 2.

Отступ классификатора

Для верного прогноза класса +1 нужен $z > 0$, а класса –1 нужен $z < 0$.
Умножим скор z_i на истинную метку s_i и получим отступ M_i.

$$M_i = s_i z_i = s_i(w^\top x_i + b)$$

Истинный класс s	Скор z	Отступ M = s · z	Прогноз
+1	2	2	Верный
–1	–2	2	Верный
+1	–0,5	–0,5	Ошибка

Верная классификация всех объектов: $M_i > 0$ для каждого i.

Масштаб скора не меняет границу

Для наших точек модели $z = x_1$ и $z = 5x_1$ дают одинаковые классы.
Их граница совпадает: $x_1 = 0$. Но значения отступа различаются.

Модель	Ближайший объект +1	Ближайший объект –1
$z = x_1$	$z = 1$, $M = 1$	$z = -1$, $M = 1$
$z = 5x_1$	$z = 5$, $M = 5$	$z = -5$, $M = 5$

Чтобы сравнивать границы, зафиксируем масштаб:

у ближайших объектов $M = 1$, у остальных $M \geq 1$.
В примере для этого делим веса второй модели на 5.

Расстояние до границы и ширина полосы

Расстояние d_i: модуль скора, делённый на длину вектора весов.

$$\|w\| = \sqrt{w_1^2 + w_2^2}, \qquad d_i = \frac{|z_i|}{\|w\|} = \frac{M_i}{\|w\|}$$

У ближайших объектов M = 1. Полная ширина полосы B = $2d_{min}$.

$$d_{\min} = \frac{1}{\|w\|}, \qquad B = 2d_{\min} = \frac{2}{\|w\|}$$

До нормировки: $z = 5x_1$, $\|w\| = 5$, расстояние $d_{min} = 5 / 5 = 1$.
После нормировки: $z = x_1$, $\|w\| = 1$, расстояние $d_{min} = 1 / 1 = 1$.

SVM для разделимых данных

Хотим широкую полосу: уменьшаем $\|w\|^2$.

При этом каждый объект должен остаться за своим краем полосы:
для класса +1 нужно $z_i \geq 1$, для класса –1 нужно $z_i \leq -1$.

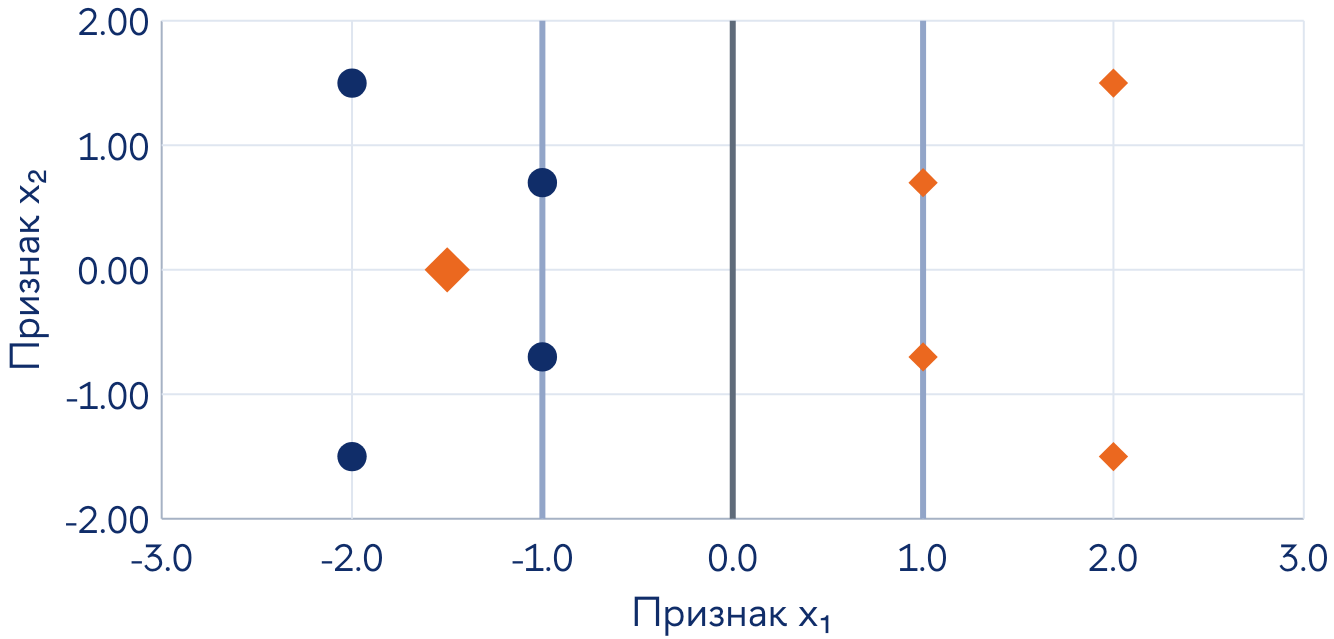
$$\min_{w,\,b} \ \frac{1}{2}\|w\|^2$$

$$s_i(w^\top x_i + b) \geq 1 \qquad i = 1, \ldots, n$$

Ограничения сохраняют верные классы и запрещают точкам входить в полосу.

Если классы нельзя разделить прямой

Добавим оранжевую точку внутрь группы синих.
Теперь ни одна прямая не разделит все объекты без ошибок.



Разрешим отдельным объектам нарушить условие $M_i \geq 1$.
За величину нарушения добавим штраф.

У новой точки при $z = x_1$:
$s = +1$, $z = -1{,}5$, $M = -1{,}5$.
До требуемого $M = 1$
не хватает 2,5.

Величина нарушения и hinge loss

Считаем, сколько отступу M не хватает до 1.
Если M уже не меньше 1, штраф равен нулю.

Отступ M	Положение объекта	Сколько не хватает до 1
1,5	Верный класс, вне полосы	0
0,5	Верный класс, внутри полосы	0,5
–1,5	Ошибка классификации	2,5

Эту функцию называют hinge loss:

$$L_{\text{hinge}}(M) = \max(0, 1 - M)$$

Обучение SVM и параметр C

Теперь учитываем и ширину полосы, и величину нарушений.
Минимизируем сумму двух слагаемых:

$$Q(w,b) = \tfrac{1}{2}\|w\|^2 + C \cdot \tfrac{1}{n}\sum_{i=1}^{n} L_{\text{hinge}}(M_i)$$

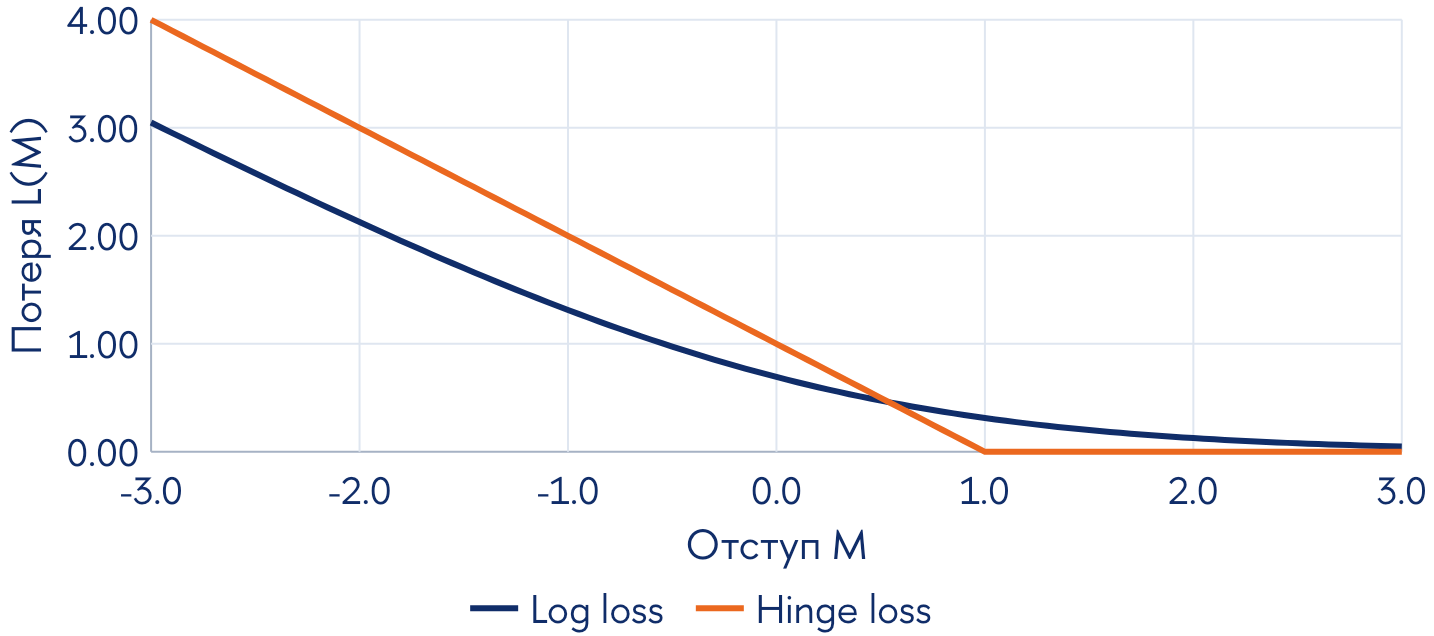
½||w||² — Уменьшение нормы расширяет полосу.

C · средняя потеря — Большое C сильнее штрафует нарушения.
Малое C допускает их ради более широкой полосы.

C выбираем по качеству на валидационной выборке.

Log loss и hinge loss

Обе функции зависят от отступа $M = s \cdot z$.
При верном классе $M > 0$, при ошибке $M < 0$.



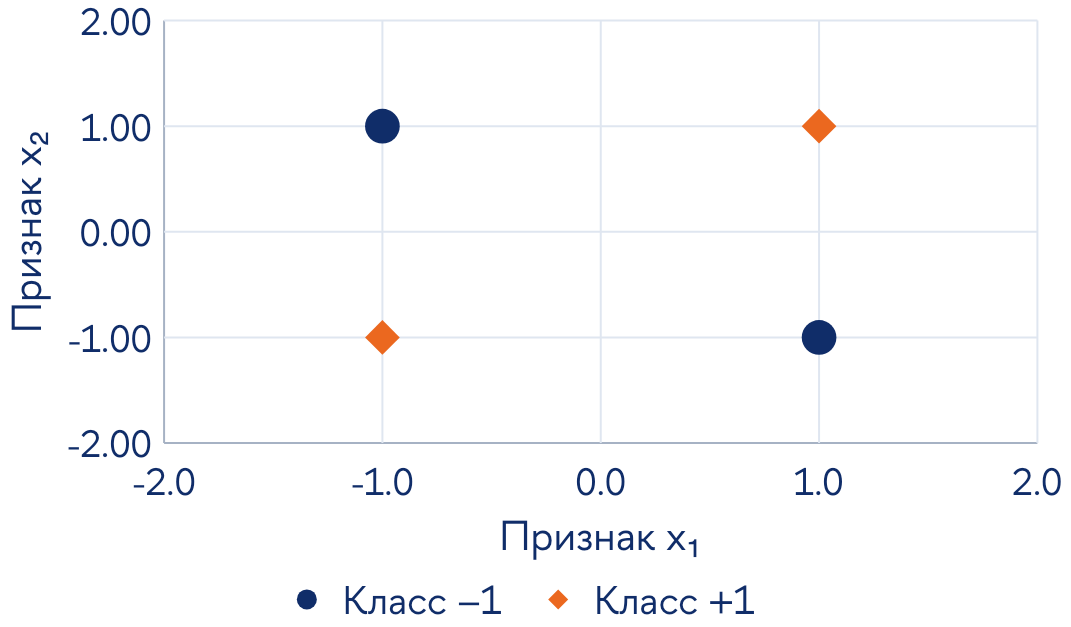
При $M \geq 1$ hinge loss равна 0.
Объект уже за краем полосы.

Log loss убывает и дальше: более уверенный верный прогноз получает меньшую потерю.

Когда нужен нелинейный признак

Четыре точки на рисунке нельзя разделить прямой.

Добавим признак $u = x_1 x_2$ и посчитаем его для каждой точки.



x_1	x_2	Класс s	$u = x_1 x_2$
–1	–1	+1	+1
1	1	+1	+1
–1	1	–1	–1
1	–1	–1	–1

По новому признаку классы разделяются порогом $u = 0$.

Ядро: работа с новыми признаками

В примере получили новый вектор признаков $\phi(x) = (x_1, x_2, x_1x_2)$.
SVM можно записать через скалярные произведения таких векторов.

Ядро K(x, t) вычисляет это произведение по исходным объектам x и t:

$$K(x,t) = \varphi(x)^\top \varphi(t)$$

Например, для наших трёх признаков:

$$K(x,t) = x_1t_1 + x_2t_2 + (x_1x_2)(t_1t_2)$$

Можно обучать SVM, не сохраняя все новые признаки явно.

Логистическая регрессия и SVM

	Логистическая регрессия	SVM
Обучение	Log loss + регуляризация	Hinge loss + регуляризация
Прогноз	Вероятность $p = \sigma(z)$	Скор z и класс по его знаку
Если нужна вероятность	Проверяем калибровку	Обучаем калибровку скора

Для SVM масштаб признаков меняет расстояния и положение границы.
Параметры масштабирования оцениваем на обучающей выборке.

В задаче выбора баннера по $p \cdot c$ нам нужны оценки вероятности клика.

Калибровка на новых данных

Выберем 1000 новых показов со средней предсказанной вероятностью клика 0,1. По модели ожидаем около 100 кликов.

В этой группе	Клики
Ожидаем по прогнозам модели	Около 100 из 1000
Наблюдаем в данных	60 из 1000

Для проверки калибровки сравниваем средний прогноз с долей кликов в разных группах показов.



Вопросы

От логарифма шансов к сигмоиде

Полагаем, что логарифм шансов равен линейному скору z.

$$\ln \frac{p}{1-p} = z \quad \Longrightarrow \quad \frac{p}{1-p} = e^z$$

Умножаем на 1 – p и собираем слагаемые с p:

$$p = e^z(1-p) \quad \Longrightarrow \quad p(1+e^z) = e^z$$

$$p = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}}$$

Вывод производной p – y

$$\frac{dL}{dp} = -\frac{y}{p} + \frac{1-y}{1-p} = \frac{p-y}{p(1-p)}$$

$$\frac{dp}{dz} = p(1-p), \qquad \frac{dL}{dz} = \frac{dL}{dp}\frac{dp}{dz} = p - y$$

Для квадрата ошибки остаётся дополнительный множитель p(1 – p).

$$\frac{d}{dz}(p-y)^2 = 2(p-y)p(1-p)$$