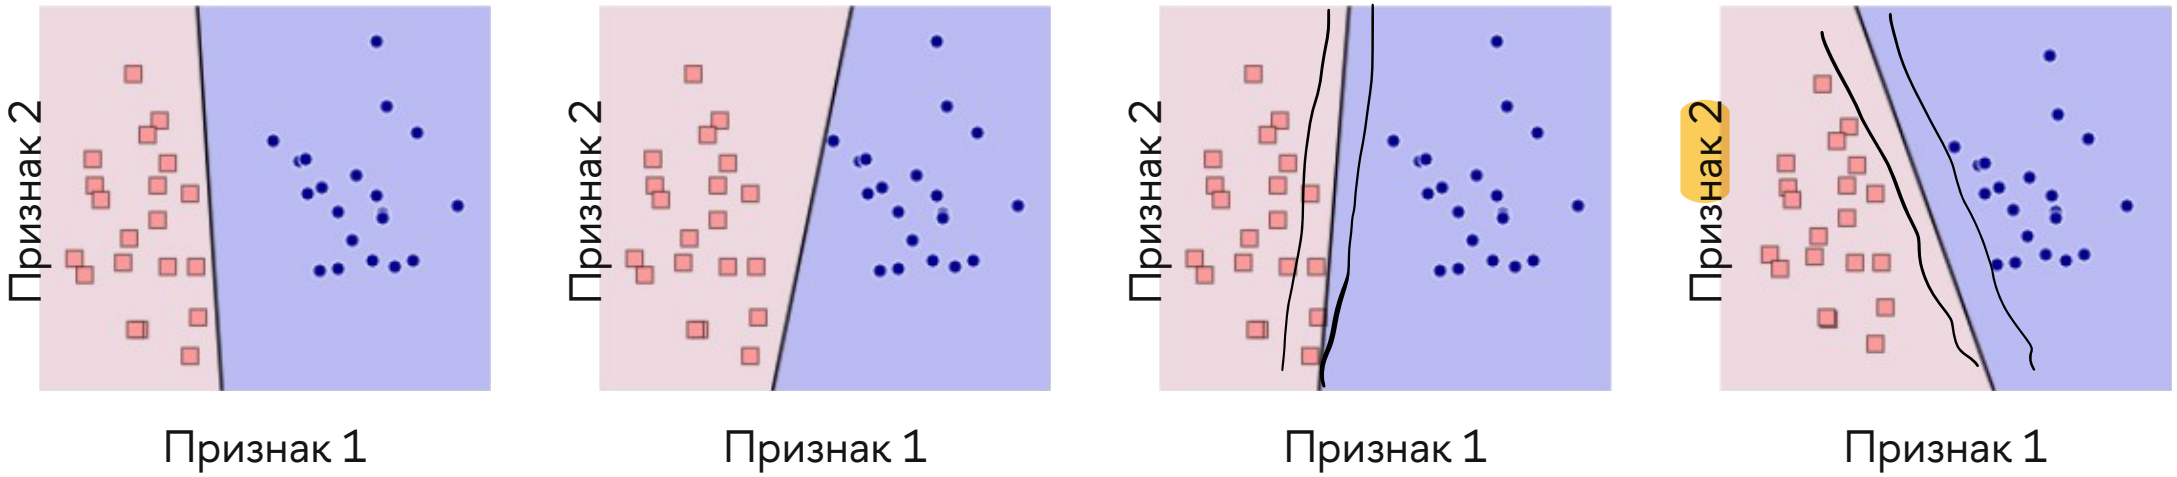
Метод опорных векторов (SVM)

Метод опорных векторов

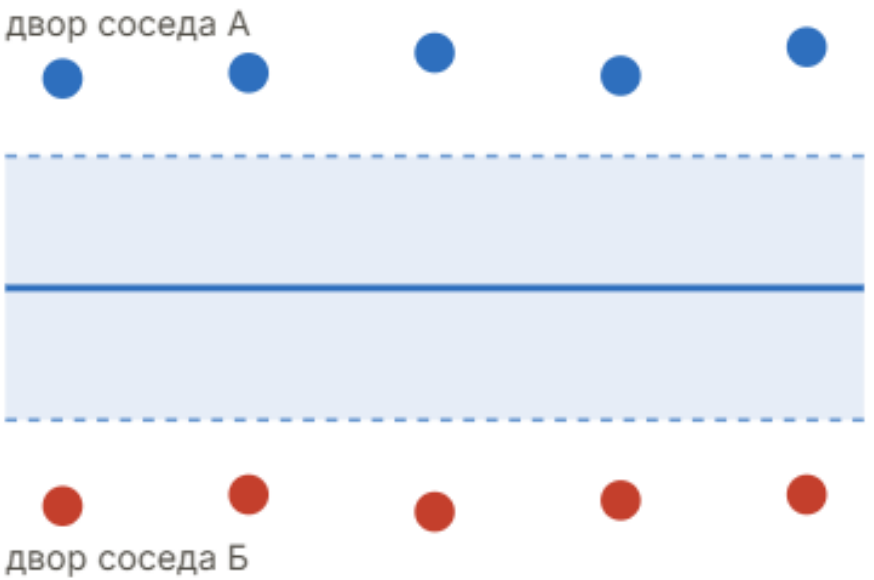
Support Vector Machine (SVM) – это алгоритм классификации, который ищет разделяющую гиперплоскость с максимальным отступом (margin) между классами.



Строительство забора между двух дворов

Если один сосед держит собаку, а другой – курей, забор логичнее ставить не впритык к одному из дворов, а точно посередине нейтральной полосы. Тогда у обоих соседей будет одинаковый запас безопасности.

SVM решает точно такую же задачу: не просто разделить два класса, а провести границу так, чтобы расстояние до ближайших точек обоих классов было максимальным



Метод опорных векторов

Откуда появились «векторы» в названии?

Вектор в SVM – это объект данных, представленный как точка в n-мерном пространстве признаков.

Ключевые элементы

Каждый объект – вектор признаков.

$$\mathbf{x} = (x_1, x_2, \ldots, x_n)$$

Гиперплоскость – линейная граница.

$$\mathbf{w} \cdot \mathbf{x} + b = 0$$

Вектор весов w диктует ориентацию границы (перпендикулярен гиперплоскости).

Параметр b определяет смещение относительно вектора w.

Условия разделения

$$\mathbf{w} \cdot \mathbf{x}_i + b \geq +1 \text{ для } y_i = +1$$

$$\mathbf{w} \cdot \mathbf{x}_i + b \leq -1 \text{ для } y_i = -1$$

Метод опорных векторов

Почему векторы «опорные»?

Опорные векторы – это точки, для которых:

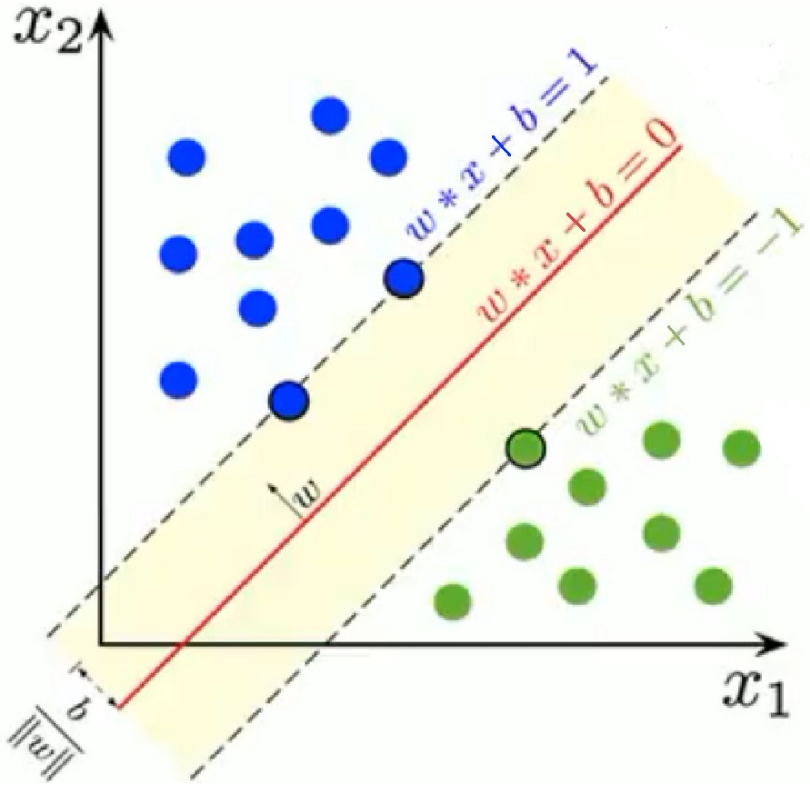
→ $\langle \mathbf{w}, \mathbf{x} \rangle + b = 1$ (для класса +1),

→ $\langle \mathbf{w}, \mathbf{x} \rangle + b = -1$ (для класса –1).

Если убрать все точки, кроме опорных векторов, гиперплоскость останется той же. Здесь опорные точки как бы держат границы отступа.

При этом отступ между крайними точками классов должен быть максимально широким.

Формализуем определение таких точек.



Математическая постановка

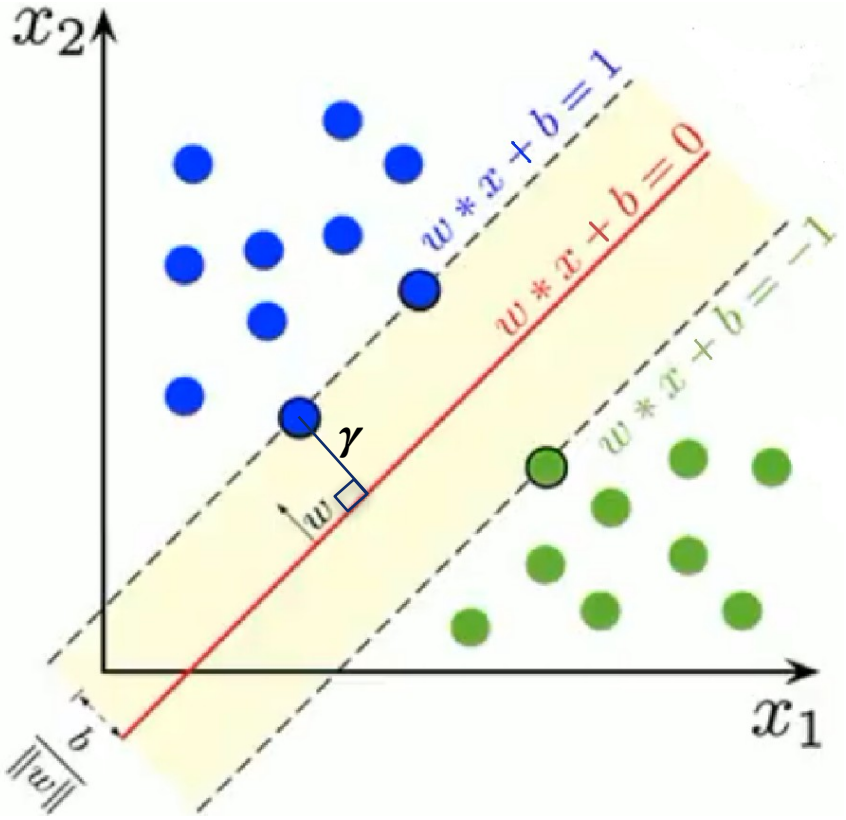
Расстояние между точкой и гиперплоскостью:

$$\text{Расстояние} = \frac{|\langle w, x_i \rangle + b|}{\|w\|}$$

С учетом правильной классификации:

$$\gamma_i = \frac{y_i \cdot (\langle w, x_i \rangle + b)}{\|w\|}$$

Задача: найти минимальное расстояние по всем объектам выборки (i) и максимизировать его.



Какая проблема может возникать при поиске оптимальной разделяющей гиперплоскости?

Математическая постановка

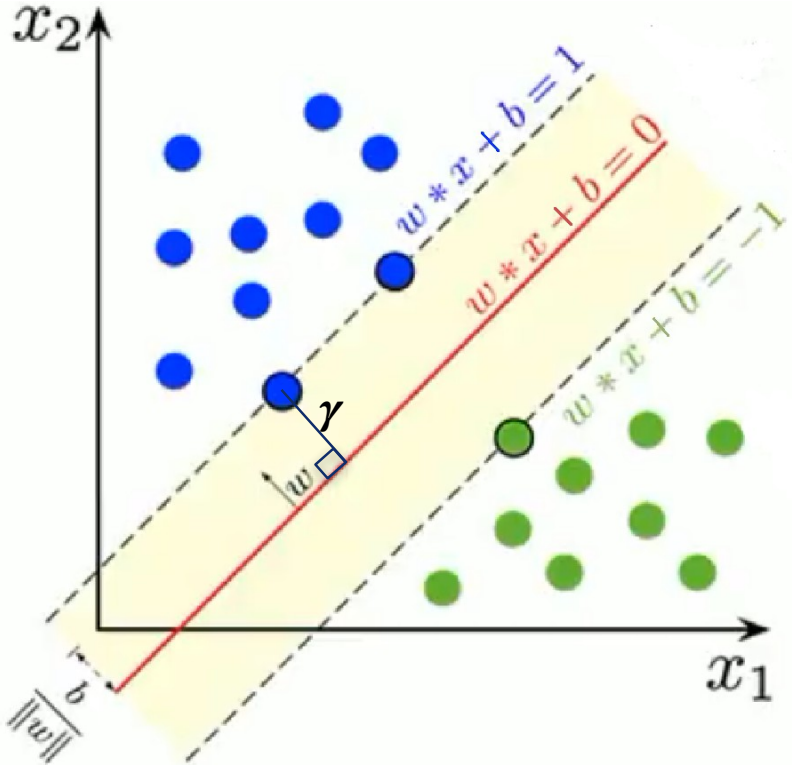
Расстояние между точкой и гиперплоскостью:

$$\text{Расстояние} = \frac{|\langle w, x_i \rangle + b|}{\|w\|}$$

С учетом правильной классификации:

$$\gamma_i = \frac{y_i \cdot (\langle w, x_i \rangle + b)}{\|w\|}$$

Задача: найти минимальное расстояние по всем объектам выборки (i) и максимизировать его.



Математическая постановка

Возникает неоднозначность:

$$\langle w, x \rangle + b \quad \text{и} \quad \langle cw, x \rangle + cb$$

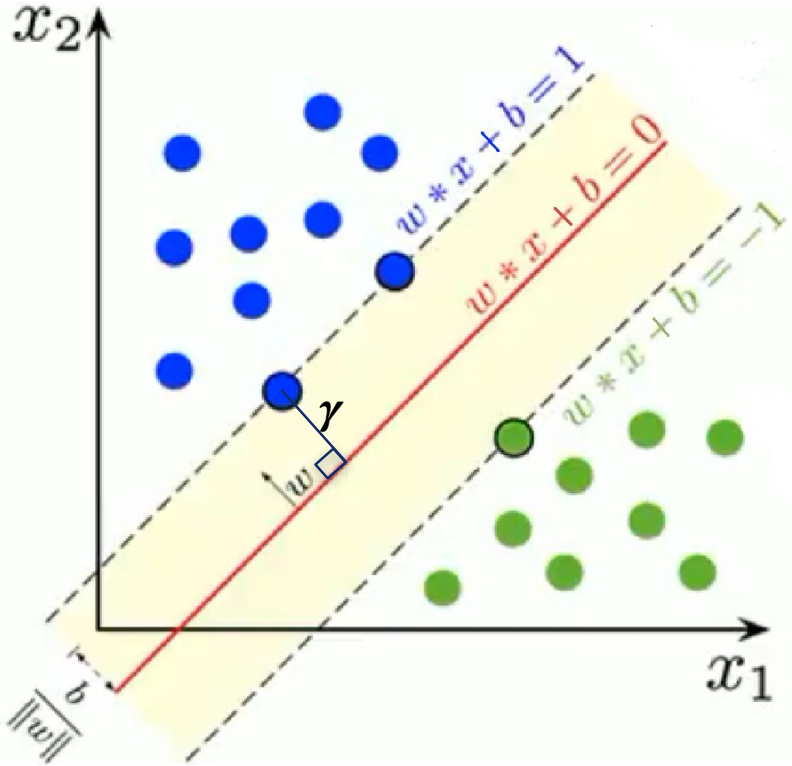
задают одну и ту же гиперплоскость.

Наложим условие на опорные вектора:

$$y_i(\langle w, x_i \rangle + b) = 1$$

Задача сводится к максимизации:

$$\gamma = \frac{1}{\|w\|}$$



Какая ширина будет у полосы между разделяющей гиперплоскостью и опорными векторами?

Вычислим ширину полосы, разделяющей классы

После нормировки ближайшие объекты классов лежат на опорных границах:

$$\langle w, x \rangle + b = 1,$$

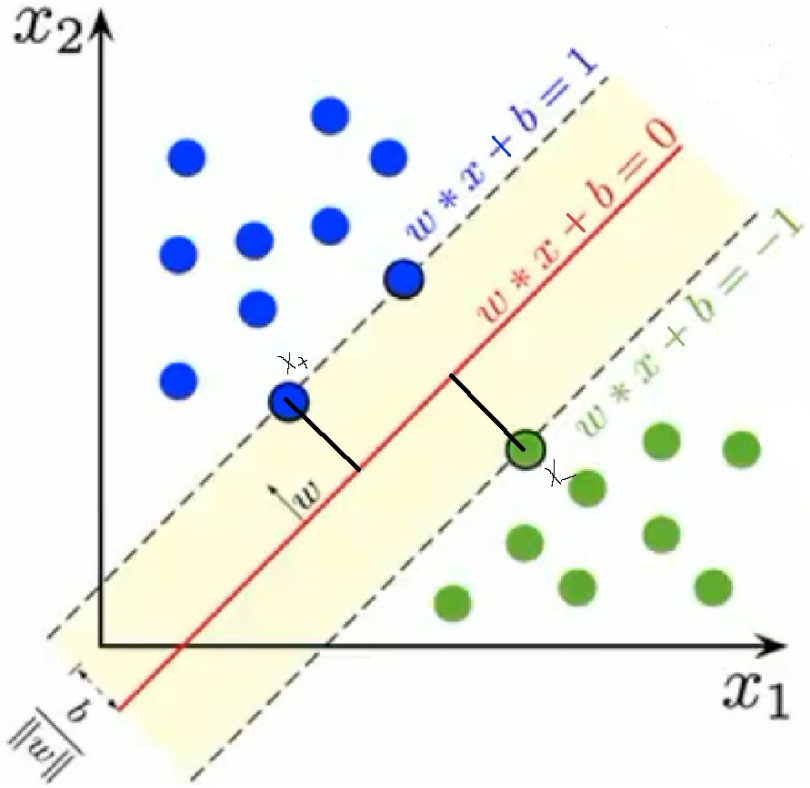
$$\langle w, x \rangle + b = -1.$$

Расстояние от точки x до разделяющей гиперплоскости $\langle w, x \rangle + b = 0$ равно:

$$\rho(x) = \frac{|\langle w, x \rangle + b|}{\|w\|}.$$

Поэтому для показанных на рисунке опорных объектов:

$$\rho(x_+) = \frac{1}{\|w\|}, \qquad \rho(x_-) = \frac{1}{\|w\|}.$$



Математическая постановка

Расстояние от центральной гиперплоскости до каждой опорной границы равно:

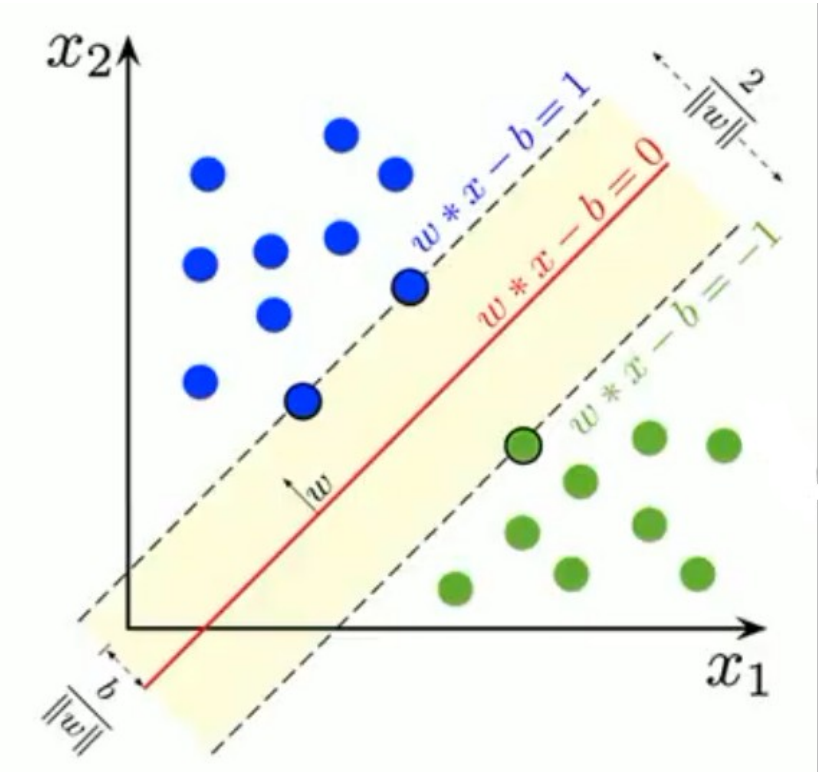
$$\frac{1}{\|w\|}.$$

Поэтому полная ширина полосы складывается из двух расстояний:

$$\text{Margin} = \rho(x_+) + \rho(x_-)$$

$$= \frac{1}{\|w\|} + \frac{1}{\|w\|} = \boxed{\frac{2}{\|w\|}}.$$

Таким образом, чем меньше норма ||w||, тем шире разделяющая полоса.



Ширина зазора и целевая функция SVM

Формула зазора

$$\text{Margin} = \frac{2}{\|\mathbf{w}\|}$$

Цель: максимизируем зазор.

$$\max \frac{2}{\|w\|} \iff \min \|w\| \iff \frac{1}{2}\|w\|^2$$

При условии, что точки классифицированы корректно:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \qquad \forall i.$$

Задача оптимизации

Для линейно разделимого случая

$$\begin{cases} \frac{1}{2}\|w\|^2 \to \min\limits_{w,b}, \\ y_i(\langle w, x_i\rangle + b) \geq 1, \quad i = 1, \ldots, \ell. \end{cases}$$

При обработке реальных данных классы часто перекрываются, и идеальная гиперплоскость не существует (линейно неразделимый случай), то есть для любых w и b найдутся точки, нарушающие условие разделения:

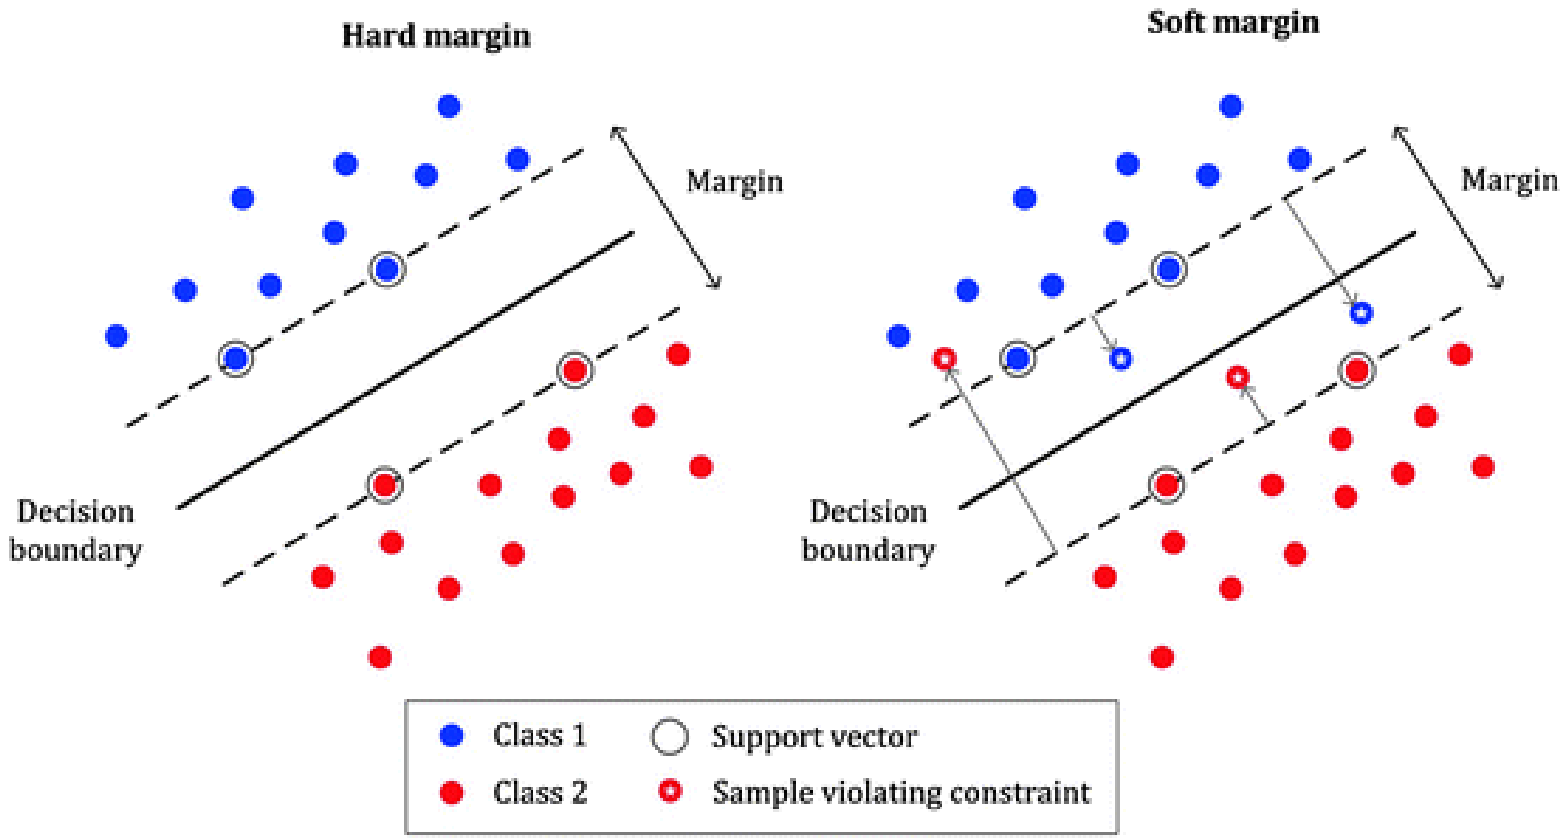
$$\exists \mathbf{x}_i \in X : \; y_i(\langle \mathbf{w}, \mathbf{x}_i\rangle + b) < 1.$$

Промежуточный итог

У нас есть работающая задача оптимизации для идеального случая: классы полностью разделимы, и мы просто минимизируем $\| w \|^2$ при выполнении жёстких условий.

Но что, если классы неразделимы линейно?

Сравнение для линейно разделимых и неразделимых данных



SVM для линейно неразделимых данных

Введём переменные, ослабляющие условия.

$$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \ldots, \ell$$

Новая задача оптимизации

$$\begin{cases} \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{\ell} \xi_i \to \min\limits_{\mathbf{w},b,\xi}, \\ y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1 - \xi_i, \\ \xi_i \geq 0, \quad i = 1, \ldots, \ell. \end{cases}$$

Итог: SVM как баланс между зазором и ошибками.

$$\underbrace{\frac{1}{2}\|\mathbf{w}\|^2}_{\text{Регуляризация (максимизация зазора)}} + \underbrace{C\sum_{i=1}^{n} \max(0, 1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b))}_{\text{Hinge loss (штраф за ошибки)}} \to \min_{\mathbf{w},b}$$

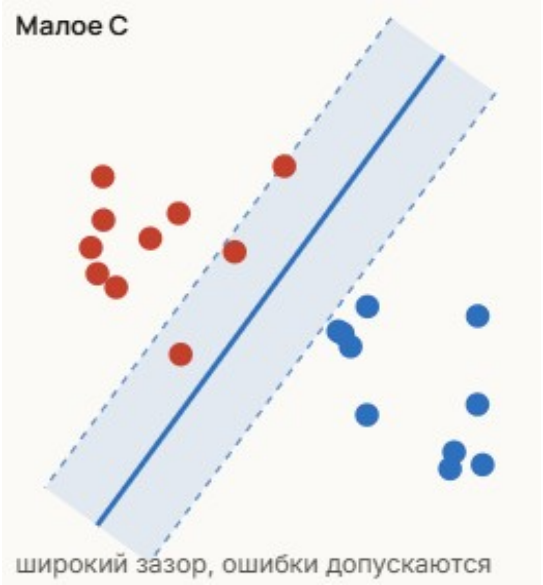
Роль гиперпараметра C в SVM

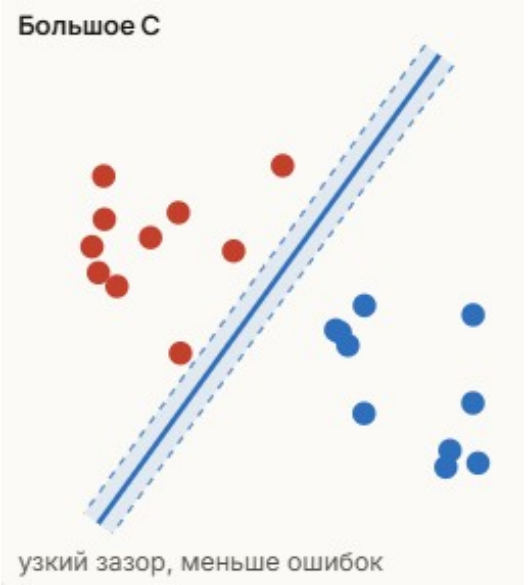
Итог: SVM как баланс между зазором и ошибками.

$$\underbrace{\frac{1}{2}\|\mathbf{w}\|^2}_{\text{Регуляризация (максимизация зазора)}} + C\underbrace{\sum_{i=1}^{n}\max(0, 1 - y_i(\mathbf{w}\cdot\mathbf{x}_i + b))}_{\text{Hinge loss (штраф за ошибки)}} \to \min_{\mathbf{w},b}$$

Малое C – модель прощает больше ошибок, зазор шире, риск недообучения.

Большое C – модель минимизирует нарушения, зазор уже, риск переобучения.





Вызов в sklearn

```
from sklearn.svm import SVC

# Обучаем модель SVM.
model_svm = SVC(
    kernel='linear',
    probability=True,
    class_weight='balanced',
    max_iter=1000,
    C=1.0
)
```

Параметры SVC

kernel – тип ядра.

probability включает расчёт вероятностей через калибровку по Платту, удобно, если хотим получить predict_proba, но делает обучение медленнее.

class_weight учитывает дисбаланс классов.

max_iter – число итераций до сходимости, нужно увеличивать при предупреждении ConvergenceWarning.

C – коэффициент штрафа за нарушения отступа. Чем больше C, тем сильнее модель штрафуется за нарушения и тем слабее регуляризация. Большое C обычно даёт более узкий зазор и повышает риск переобучения.

Вызов в sklearn

```
# Фит на данные
model_svm.fit(X_train, y_train)

# Предсказания вероятностей принадлежности к положительному классу (1)
y_pred_prob = model_svm.predict_proba(X_test)[:, 1]

# Предсказания классов
y_pred_classes = model_svm.predict(X_test)

# Доступ к коэффициентам модели (только для линейного ядра!)
print(model_svm.coef_)
print(model_svm.intercept_)
```

Отличия SVM и логистической регрессии

Отличия SVM и логистической регрессии

Критерий	SVM	Логистическая регрессия
Интерпретации	Геометрические: опорные векторы и ширина зазора, веса указывают направление и важность признаков	Вероятностные: можно оценивать риски, настраивать порог принятия решений
Чувствительность к выбросам	Менее чувствителен к далёким выбросам	Выбросы могут сильно смещать границу
Работа с большими выборками	Вычислительно сложнее (особенно с нелинейными ядрами), плохо масштабируется на миллионы объектов	Быстрее обучается, хорошо масштабируется, имеет эффективные солверы для больших данных
Вывод	Решающее правило	Вероятности
Использование	Редко в практике	Широко

Hinge loss и logistic loss

