Национальный Исследовательский
Университет «Высшая Школа Экономики»

2026

Решающие деревья

Лекция 7

Содержание

01 Устройство дерева

02 Обучение дерева

03 Критерии и выбор разбиения

04 Глубина и переобучение

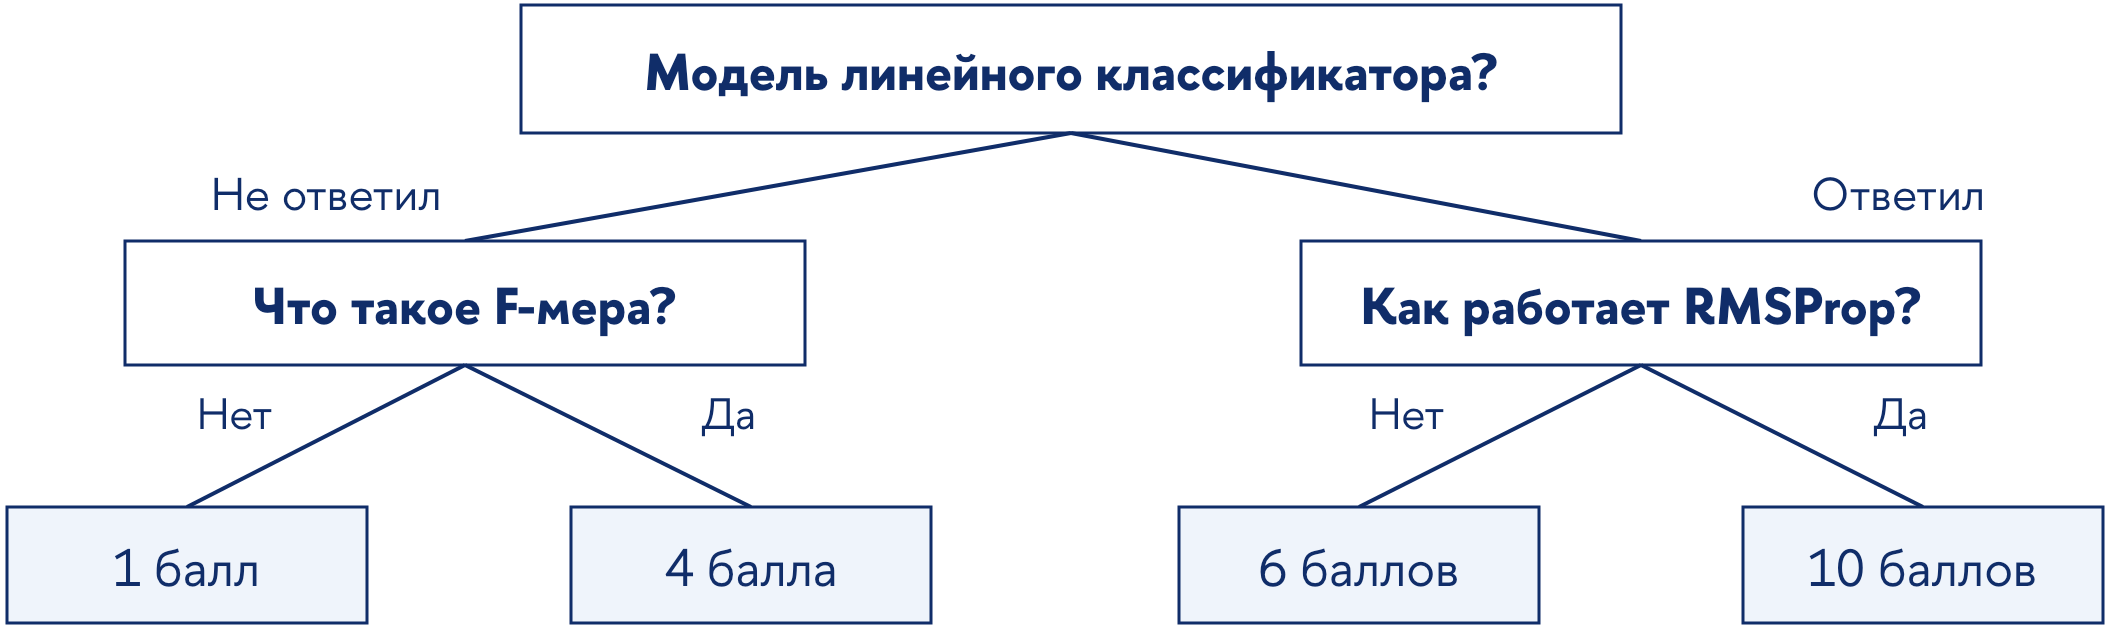
05 Практические вопросы

01 Устройство дерева

Предикаты, прогнозы в листьях
и разбиение пространства признаков

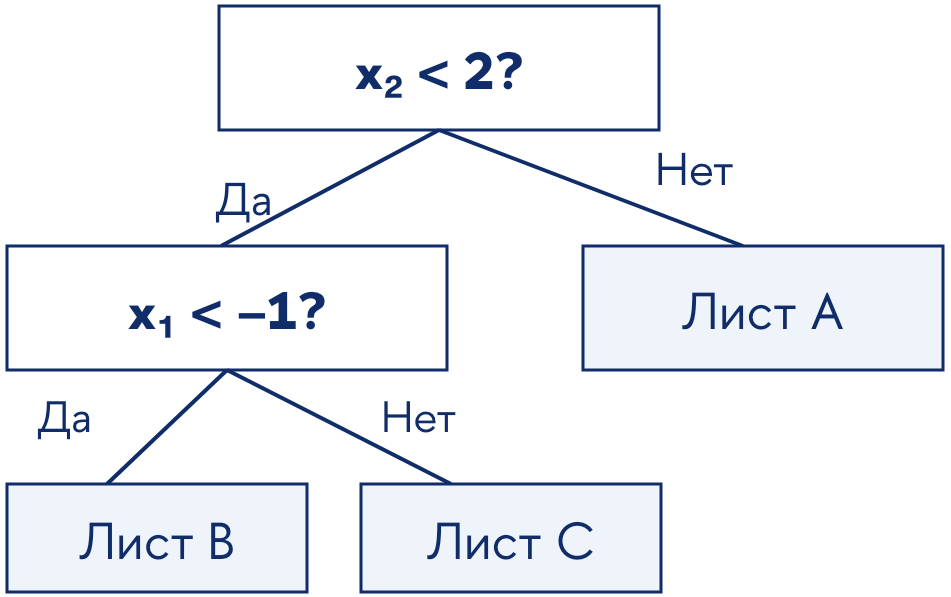
Решающее дерево на экзамене

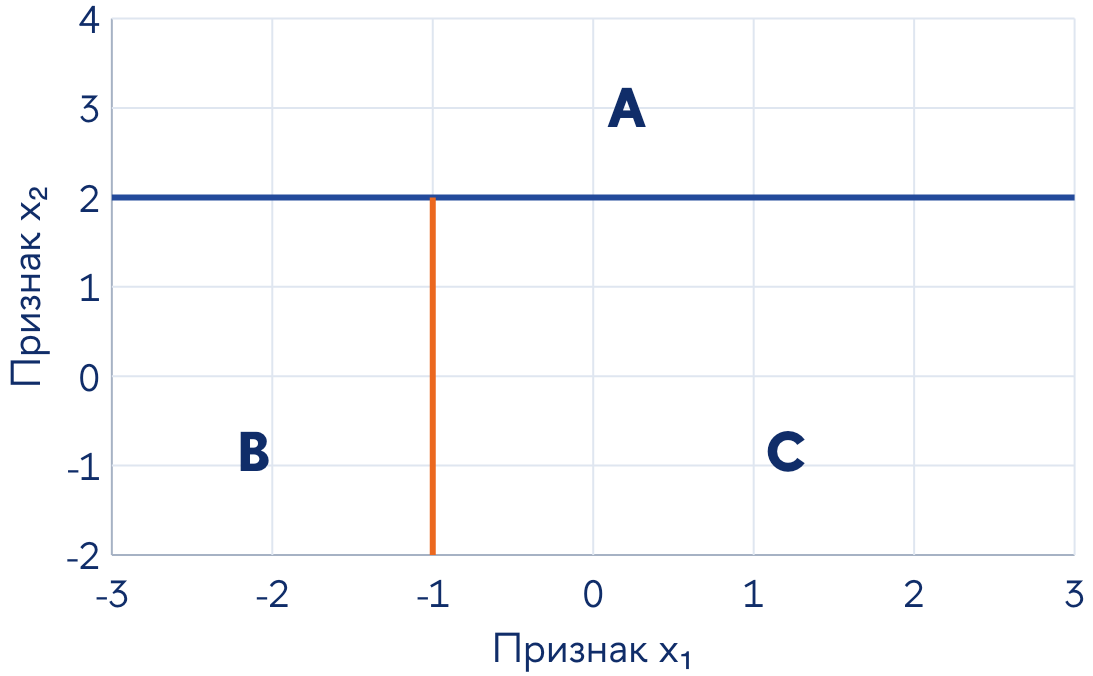
Внутренние вершины содержат вопросы. Листья содержат прогнозы.



Какие бывают предикаты?

Чаще всего сравниваем один признак с порогом: $x_j < t$.





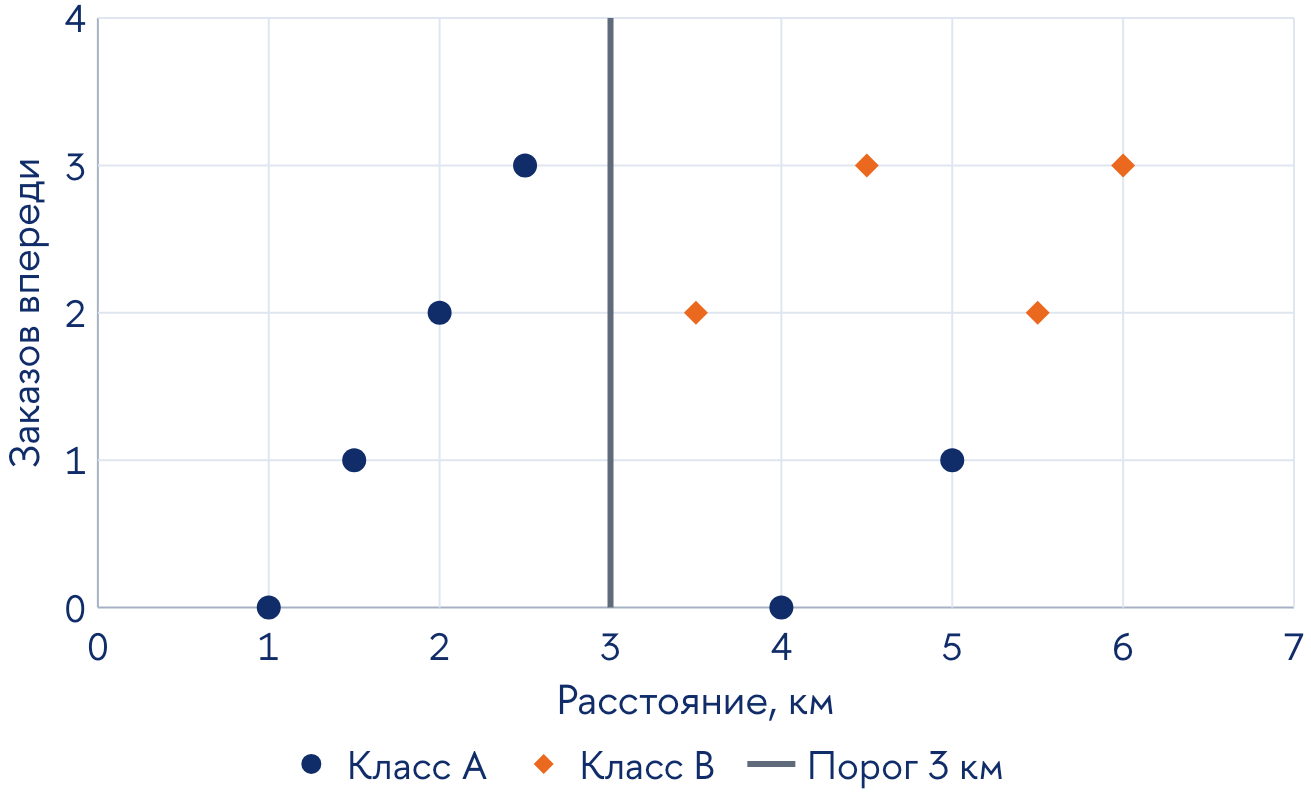
Возможны и другие условия: линейная комбинация признаков, расстояние до точки.

02 Обучение дерева

Жадное построение, условия остановки и выбор прогноза в листе

Как строится дерево

Учебная выборка: 10 объектов



1. Перебираем условия

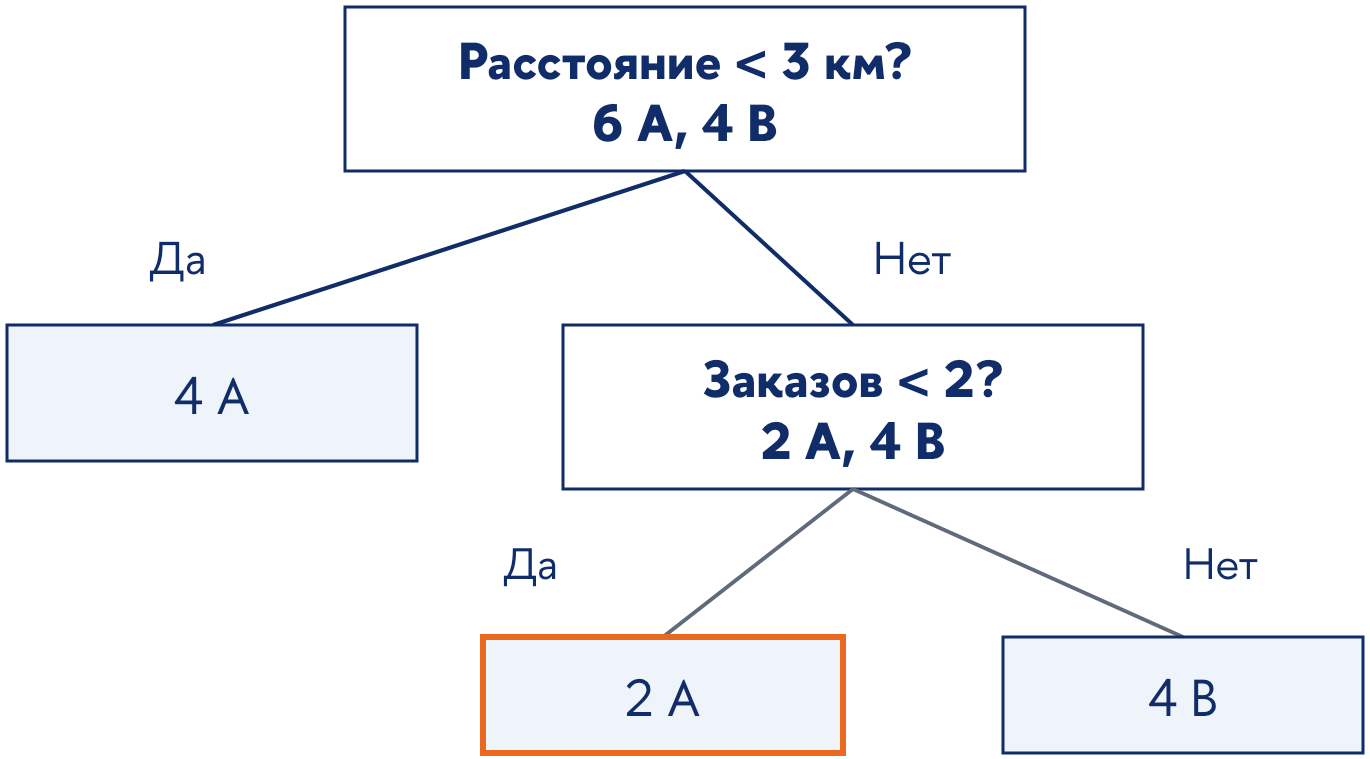
Оцениваем, как каждое условие разделяет классы.

2. Выбираем лучшее

Фиксируем разбиение и повторяем поиск в потомках.

Алгоритм жадный: готовые верхние разбиения не пересматриваем.

Когда останавливать дерево



max_depth = 1

Останавливаемся после первого разбиения. Оба потомка становятся листьями.

min_samples_leaf = 3

Разбиение 4 / 6 допустимо.
Разбиение 2 / 4 запрещено: один лист слишком мал.

Значения ограничений подбираем по валидации.

Какой прогноз записать в листе

Задача	Прогноз	Пример ответов в листе
Регрессия с MSE	Среднее	20, 22, 24 → прогноз 22
Классификация	Самый частый класс	4 из 7 объектов класса A → класс A
Вероятности классов	Доли классов	4 из 7 объектов класса A → 4/7

Прогноз зависит от функции потерь. Для MAE в регрессии берём медиану.

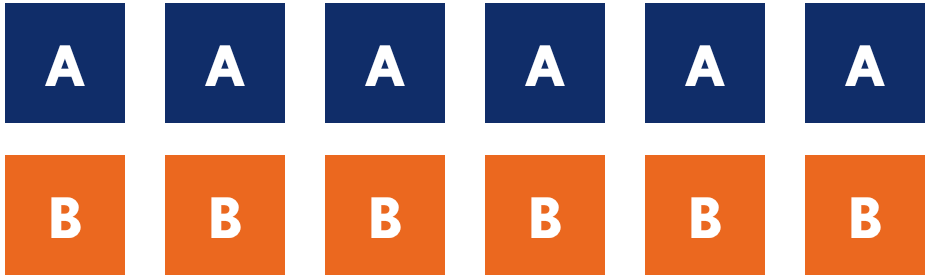
03 Критерии и выбор разбиения

MSE, доля ошибок, Джини и энтропия
Взвешенный выигрыш и перебор порогов

Неоднородность объектов в вершине

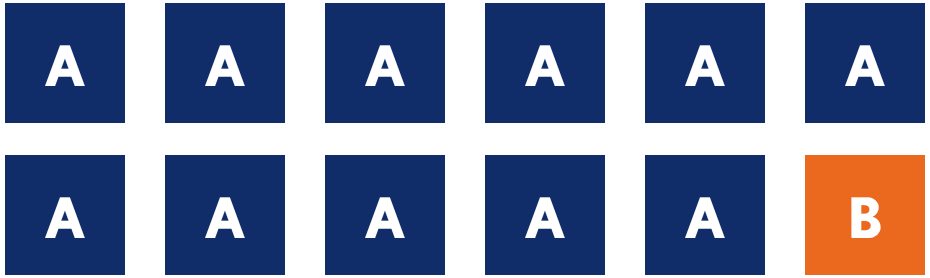
H(R) характеризует состав ответов в группе объектов R.

Классы поровну



6 A и 6 B. Высокая неоднородность.

Почти все одного класса



11 A и 1 B. Низкая неоднородность.

Критерий информативности

Один способ задать H(R): найти лучший постоянный прогноз и посчитать его среднюю потерю на объектах вершины.

$$H(R) = \min_c \frac{1}{|R|} \sum_{i \in R} L(y_i, c)$$

R: объекты, попавшие в вершину.

c: один и тот же прогноз для всех этих объектов.

L: функция потерь.

Регрессия: среднее и MSE

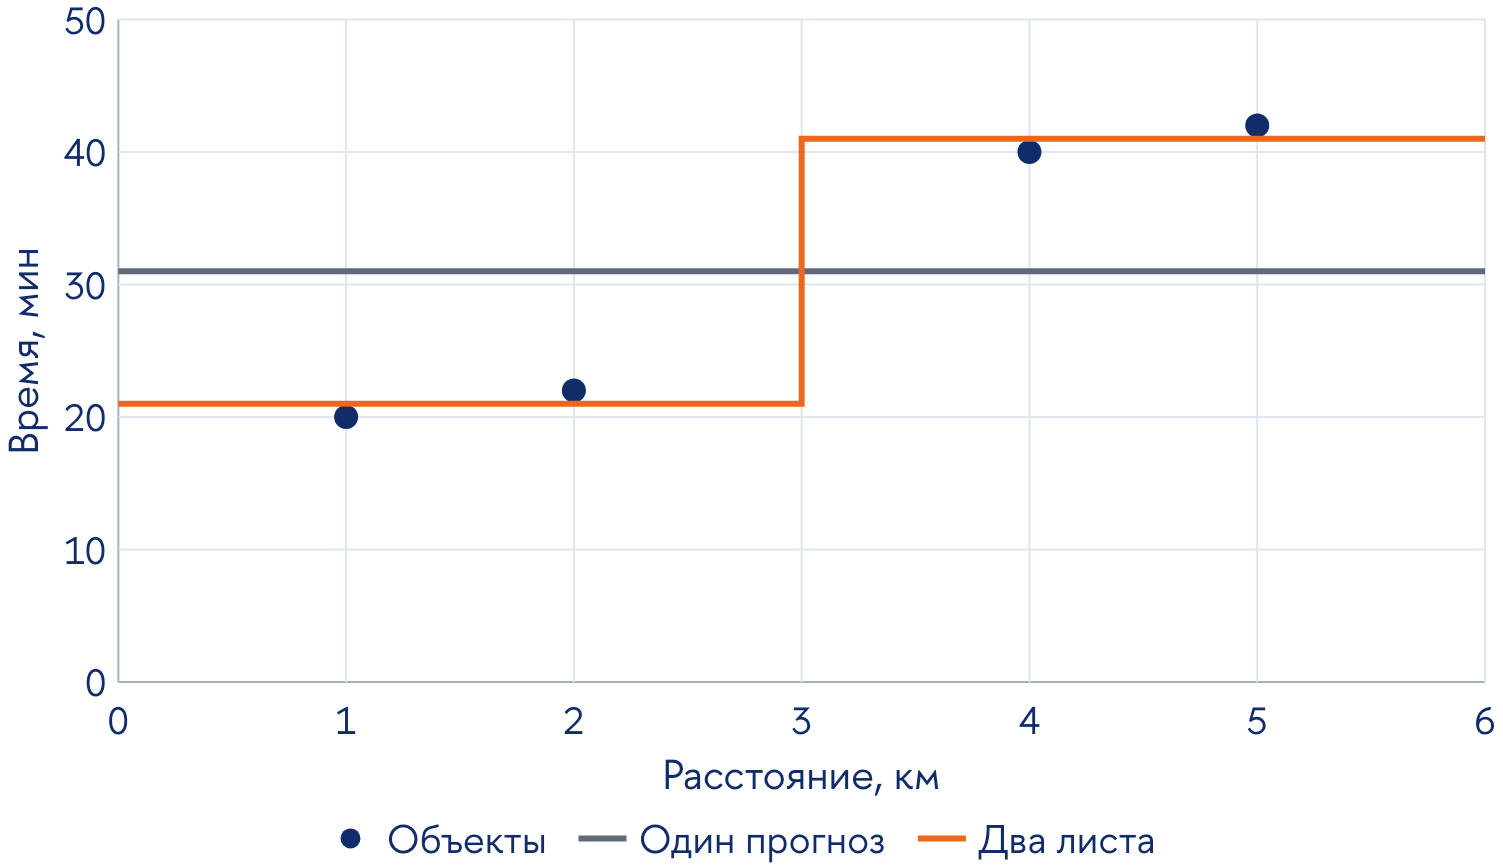
При квадратичной потере лучший прогноз в листе равен среднему ответу.

$$c = \bar{y}, \qquad H(R) = \frac{1}{|R|} \sum_{i \in R} (y_i - \bar{y})^2$$

H(R) измеряет разброс ответов вокруг среднего.

Для ответов 20, 22, 24 прогноз равен 22.
MSE = (4 + 0 + 4) / 3 ≈ 2,67.

Регрессия: что даёт разбиение



До разбиения

Прогноз: 31 мин
MSE = 101 мин²

Порог: 3 км

Прогнозы: 21 и 41
MSE = 1 мин²

Классификация: доля ошибок

Предсказываем самый частый класс в вершине.

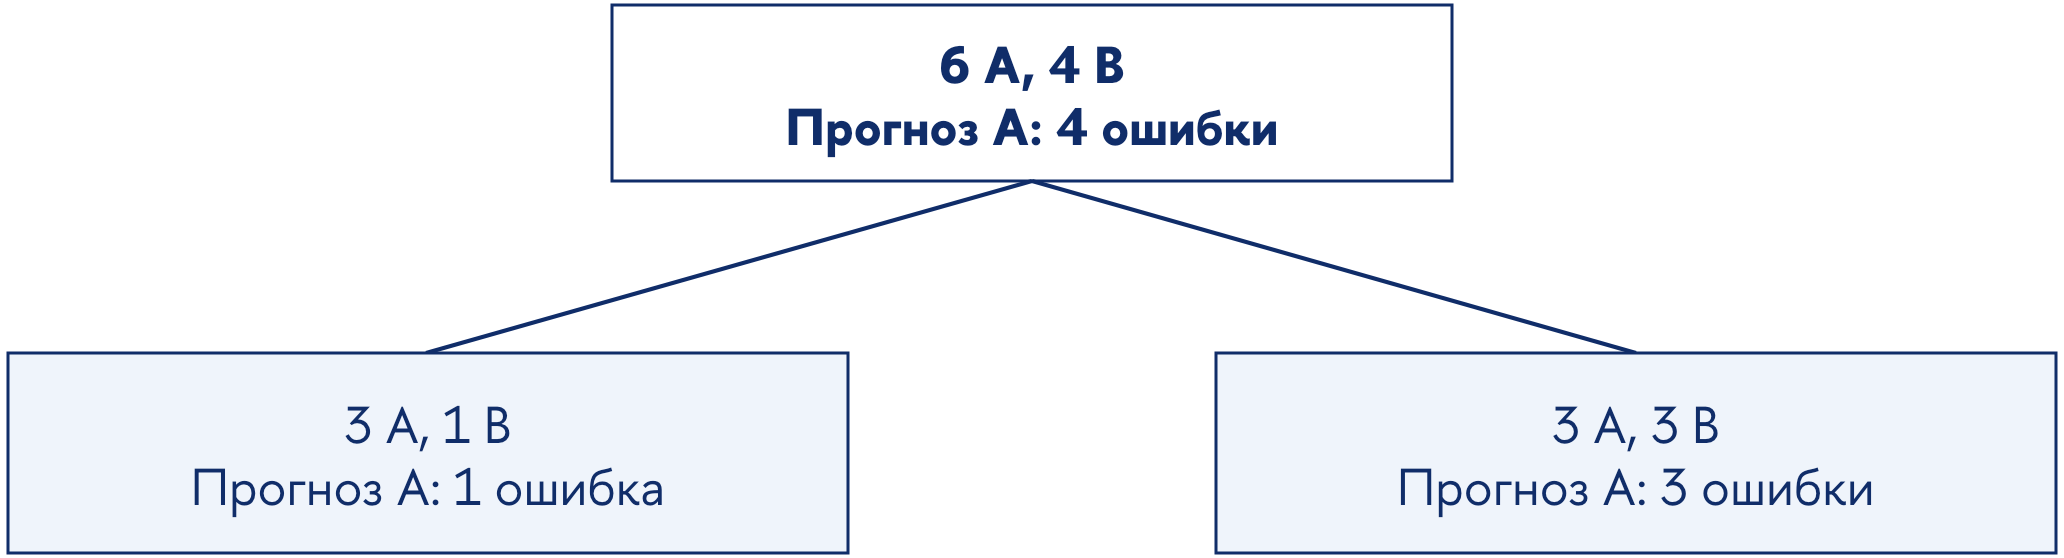
$$H(R) = 1 - \max_k p_k$$

p_k: доля объектов класса k в вершине.

Класс A	Класс B	Класс C	Прогноз
4 объекта	2 объекта	1 объект	Класс A

Три объекта получат неверный ответ. Доля ошибок: 1 – 4/7 = 3/7.

Доля ошибок может не заметить разбиение



До: 4 ошибки из 10

После: 1 + 3 = 4 из 10

Состав групп изменился, но доля ошибок не уменьшилась.

По этому критерию выигрыш равен нулю.

Критерий Джини

Учитываем доли всех K классов, а не только самого частого.

$$H(R) = \sum_{k=1}^{K} p_k(1 - p_k) = 1 - \sum_{k=1}^{K} p_k^2$$

Один класс: H(R) = 0. Два класса поровну: H(R) = 0,5.

В предыдущем примере Джини уменьшается с 0,48 до 0,45.
Это разбиение даёт небольшой выигрыш.

Энтропийный критерий

$$H(R) = -\sum_{k=1}^{K} p_k \log_2 p_k$$

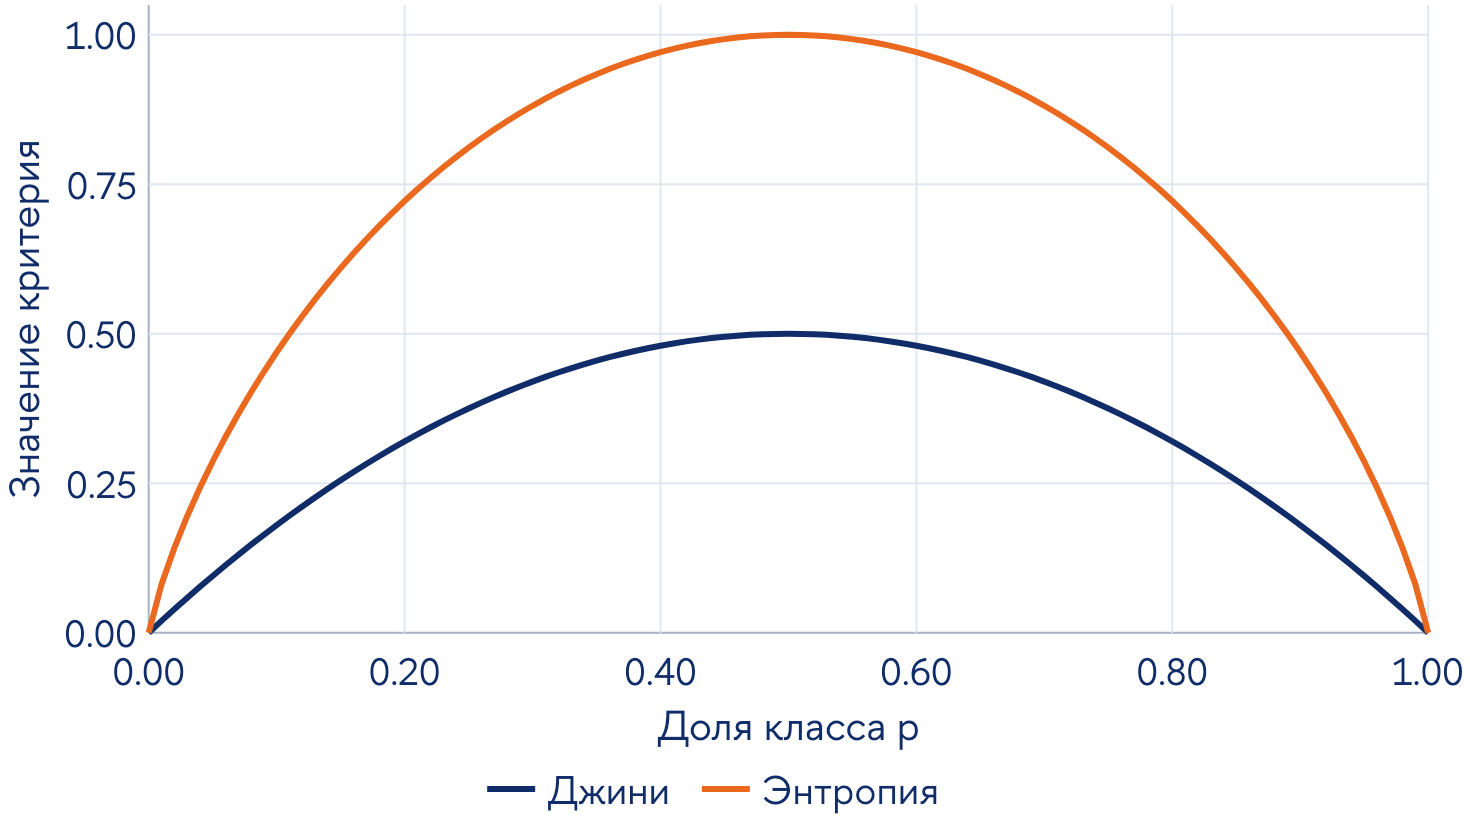
Один класс: энтропия равна нулю.

При равных долях K классов энтропия максимальна: $\log_2 K$.

Два класса поровну: $H(R) = 1$.

В слагаемых с $p_k = 0$ считаем $0 \cdot \log_2 0 = 0$.

Джини и энтропия для двух классов



Оба критерия равны нулю в чистой вершине.

Оба максимальны, когда классы встречаются одинаково часто.

Они могут выбрать разные разбиения.

Как выбрать предикат?

Сравниваем неоднородность до разбиения и после него.

$$Q = H(R) - \frac{|R_\ell|}{|R|} H(R_\ell) - \frac{|R_r|}{|R|} H(R_r)$$

R_ℓ и R_r: группы объектов после разбиения.
Их вклад учитываем пропорционально числу объектов.

Выбираем признак и порог с наибольшим выигрышем Q.

Пример расчёта выигрыша

Вернёмся к 10 доставкам. Проверяем условие «расстояние < 3 км».

Группа	Класс A	Класс B	Джини
До разбиения	6	4	$1 - 0{,}6^2 - 0{,}4^2 = 0{,}48$
Слева	4	0	0
Справа	2	4	$1 - (2/6)^2 - (4/6)^2 \approx 0{,}444$

$Q = 0{,}48 - (4/10) \cdot 0 - (6/10) \cdot 0{,}444\ldots \approx 0{,}213.$

Как выбрать порог

Та же выборка из 10 объектов



Перебираем середины

Между 2,5 и 3,5 км проверяем порог 3 км.

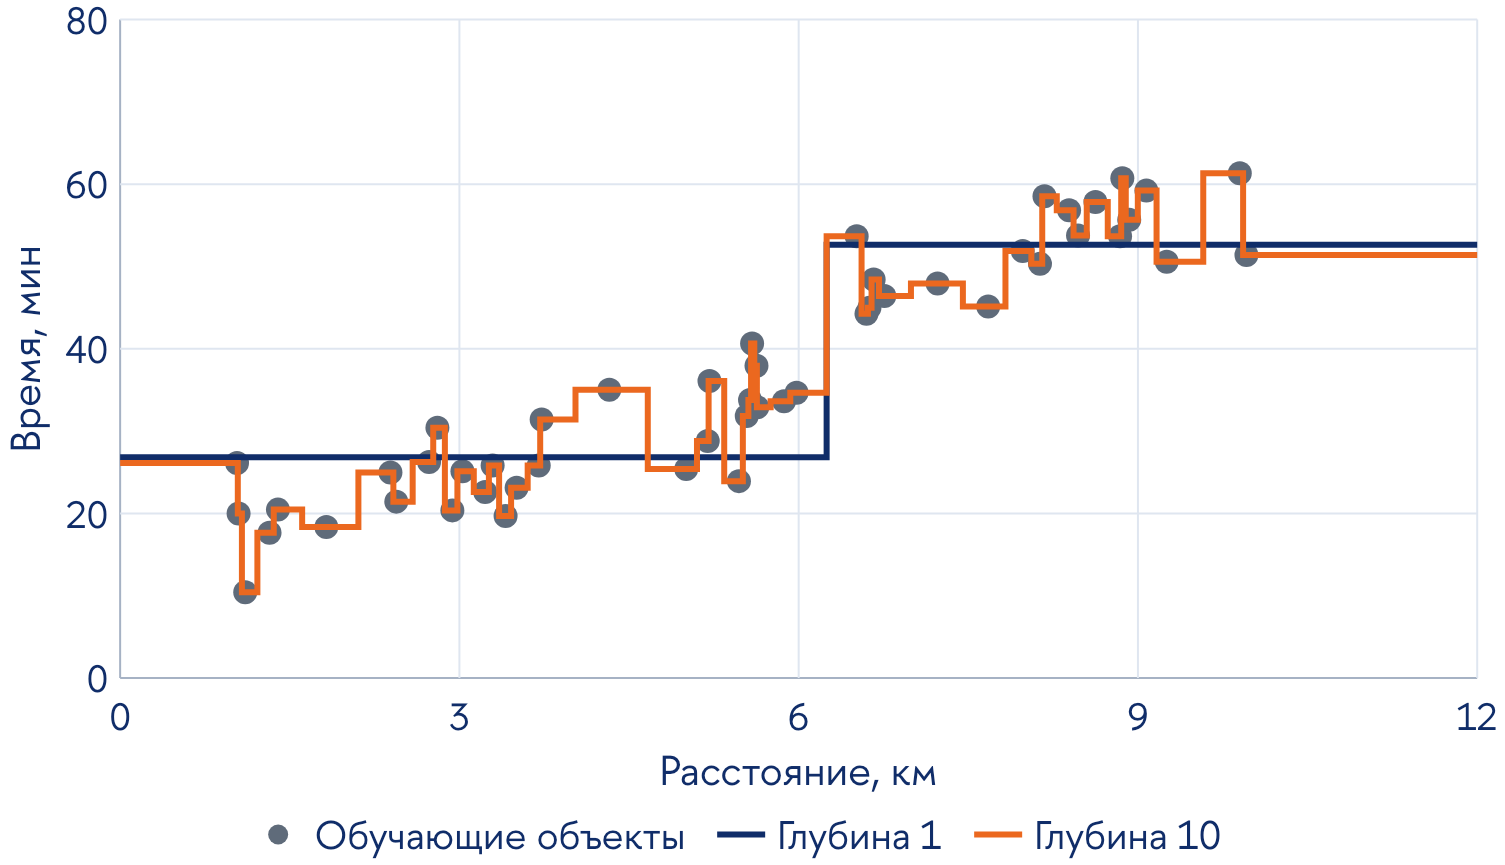
Лучший порог: 3 км
Выигрыш ≈ 0,213

Сравниваем с лучшими разбиениями по остальным признакам.

04 Глубина и переобучение

Подгонка под обучающую выборку
и выбор глубины по валидации

Глубина дерева и переобучение

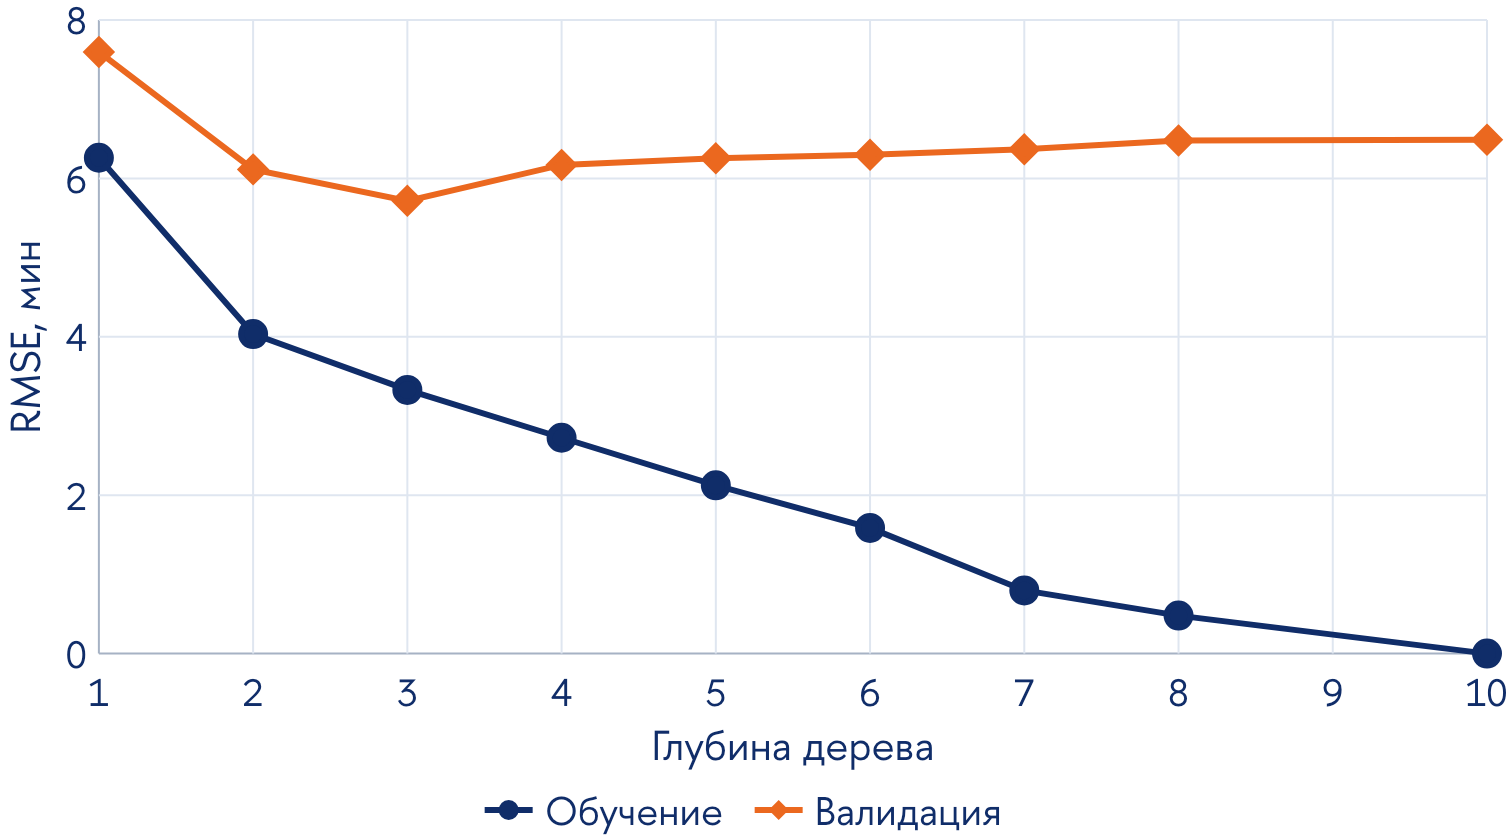


Глубокое дерево подстраивается под каждый обучающий объект.

Проверим, помогает ли это на новых данных.

Синтетические данные:
50 доставок.

Выбор глубины по валидации



Минимум на валидации

Глубина 3
RMSE ≈ 5,72 мин

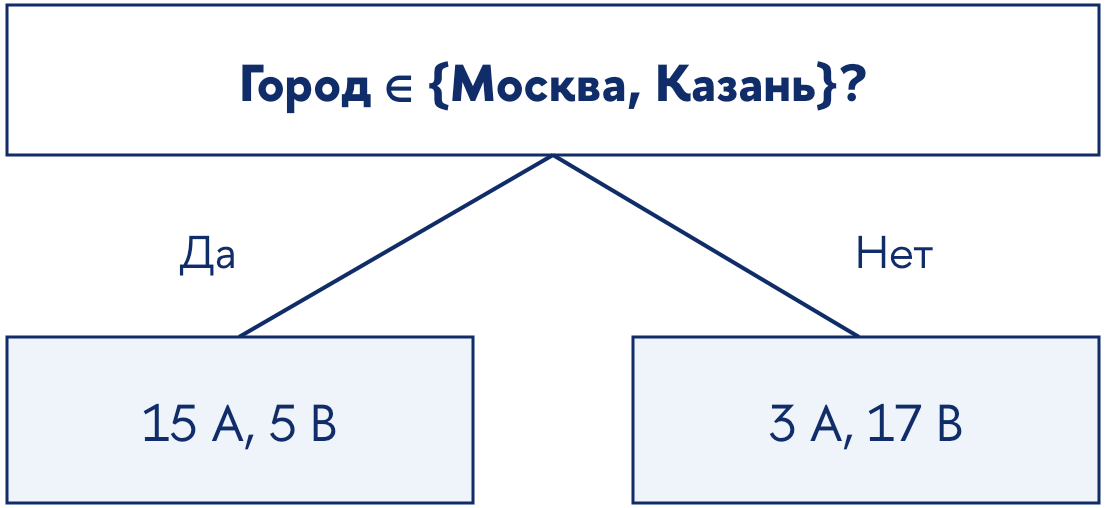
Итоговое качество проверяем на отдельной тестовой выборке.

05 Практические вопросы

Категории и пропуски, важность признаков и обучение дерева в sklearn

Разбиение по категориальному признаку

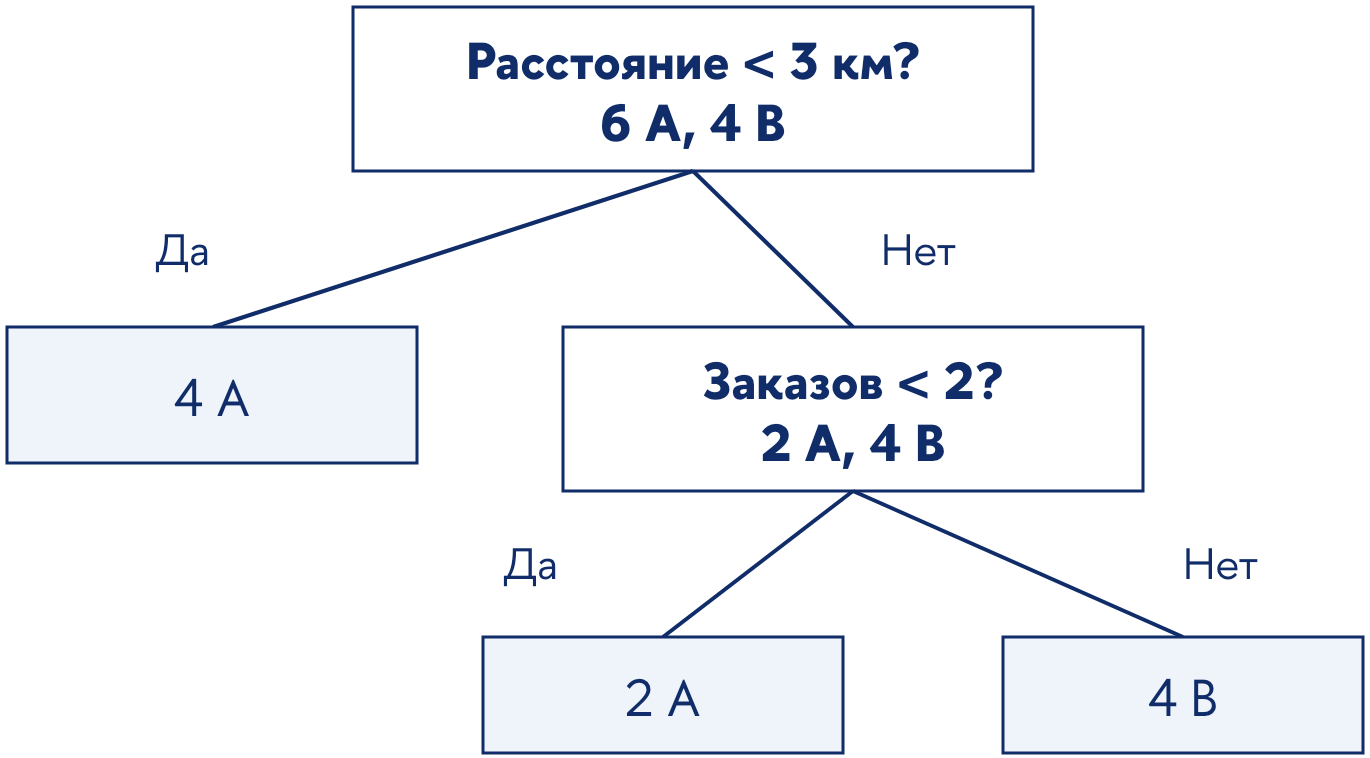
Город	Класс A	Класс B
Москва	8	2
Казань	7	3
Тула	2	8
Омск	1	9



В левую группу попали города, где чаще встречается класс A.

Если реализация не поддерживает такие условия, категории кодируют, например one-hot.

Важность признаков



Взвешенный выигрыш

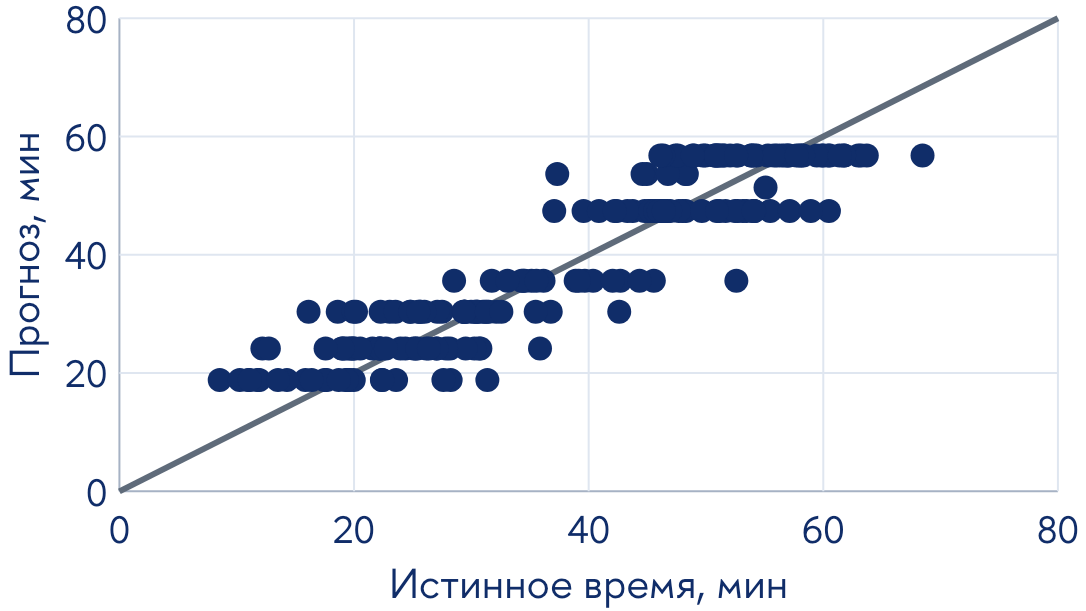
Расстояние: все 10 объектов
$1 \cdot 0{,}213 \approx 0{,}213$

Заказы: 6 из 10 объектов
$0{,}6 \cdot 0{,}444 \approx 0{,}267$

Делим вклады на их сумму:
расстояние 44%, заказы 56%.

Проверка важности перестановкой

Исходная валидация



RMSE = 5,72 мин

Расстояния перемешаны



RMSE = 20,43 мин

Серая линия: прогноз равен ответу. Одна перестановка расстояний.
Дерево глубины 3, 200 объектов валидации. Модель не переобучаем.

Обучение дерева в sklearn

```
from sklearn.tree import DecisionTreeClassifier

model = DecisionTreeClassifier(
    max_depth=3,
    min_samples_leaf=5,
    random_state=7
)
model.fit(X_train, y_train)
prediction = model.predict(X_valid)
```

Для регрессии: DecisionTreeRegressor. Пропуски можно заполнить медианой по train и добавить признак наличия пропуска.